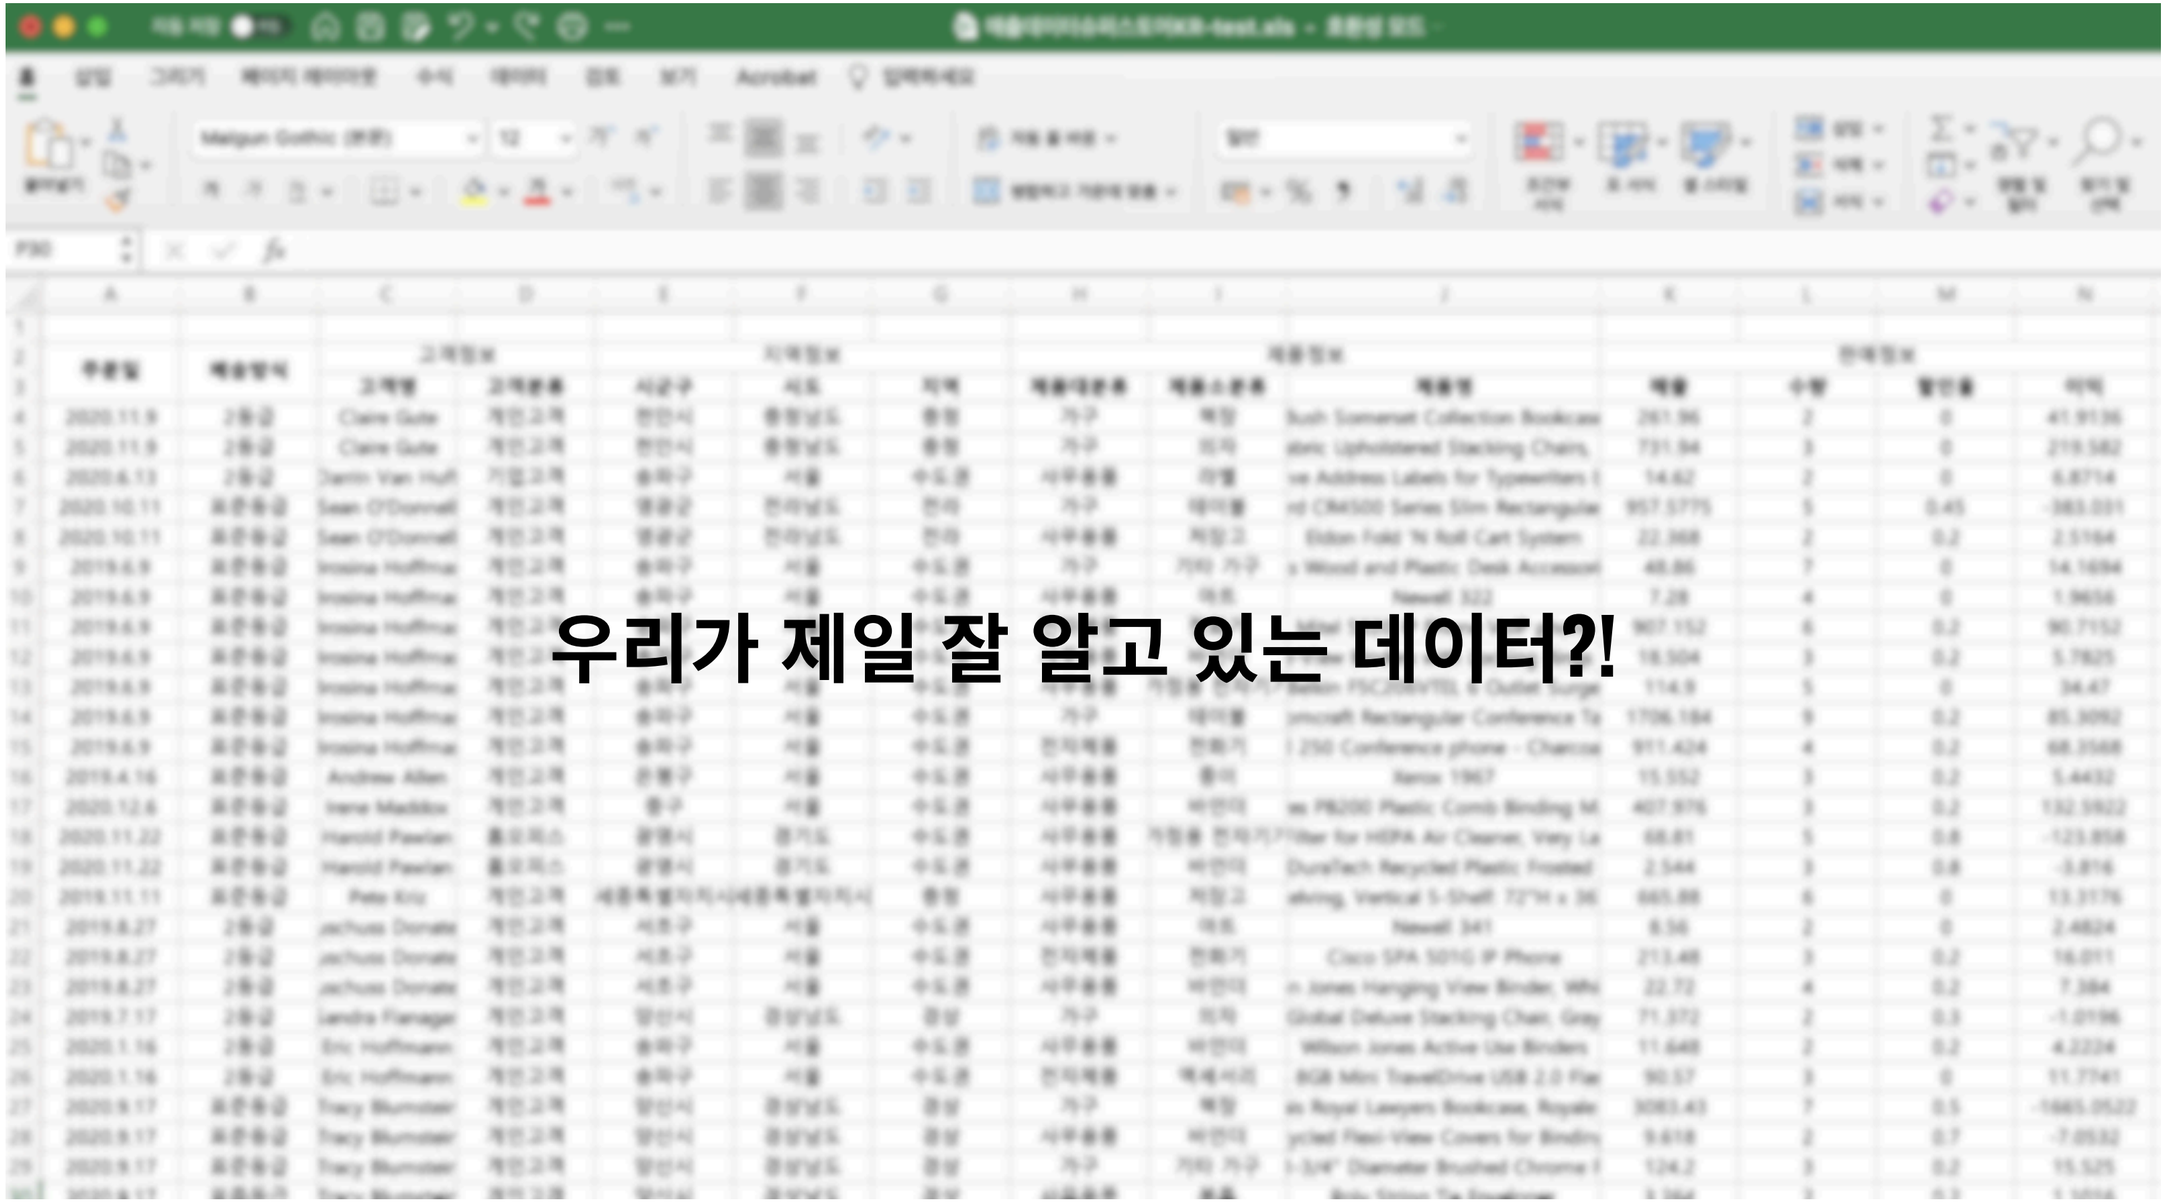
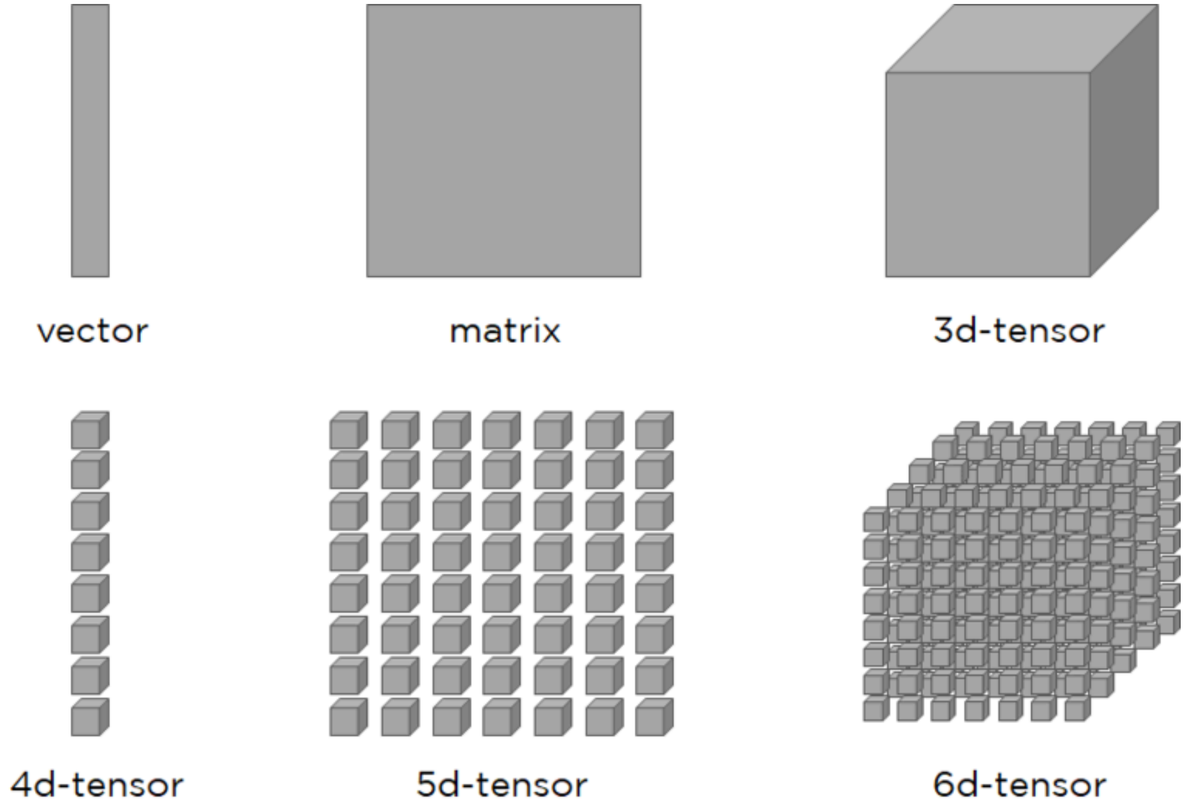
지도 *VS* 비지도 *VS* 강화학습

데이터란?

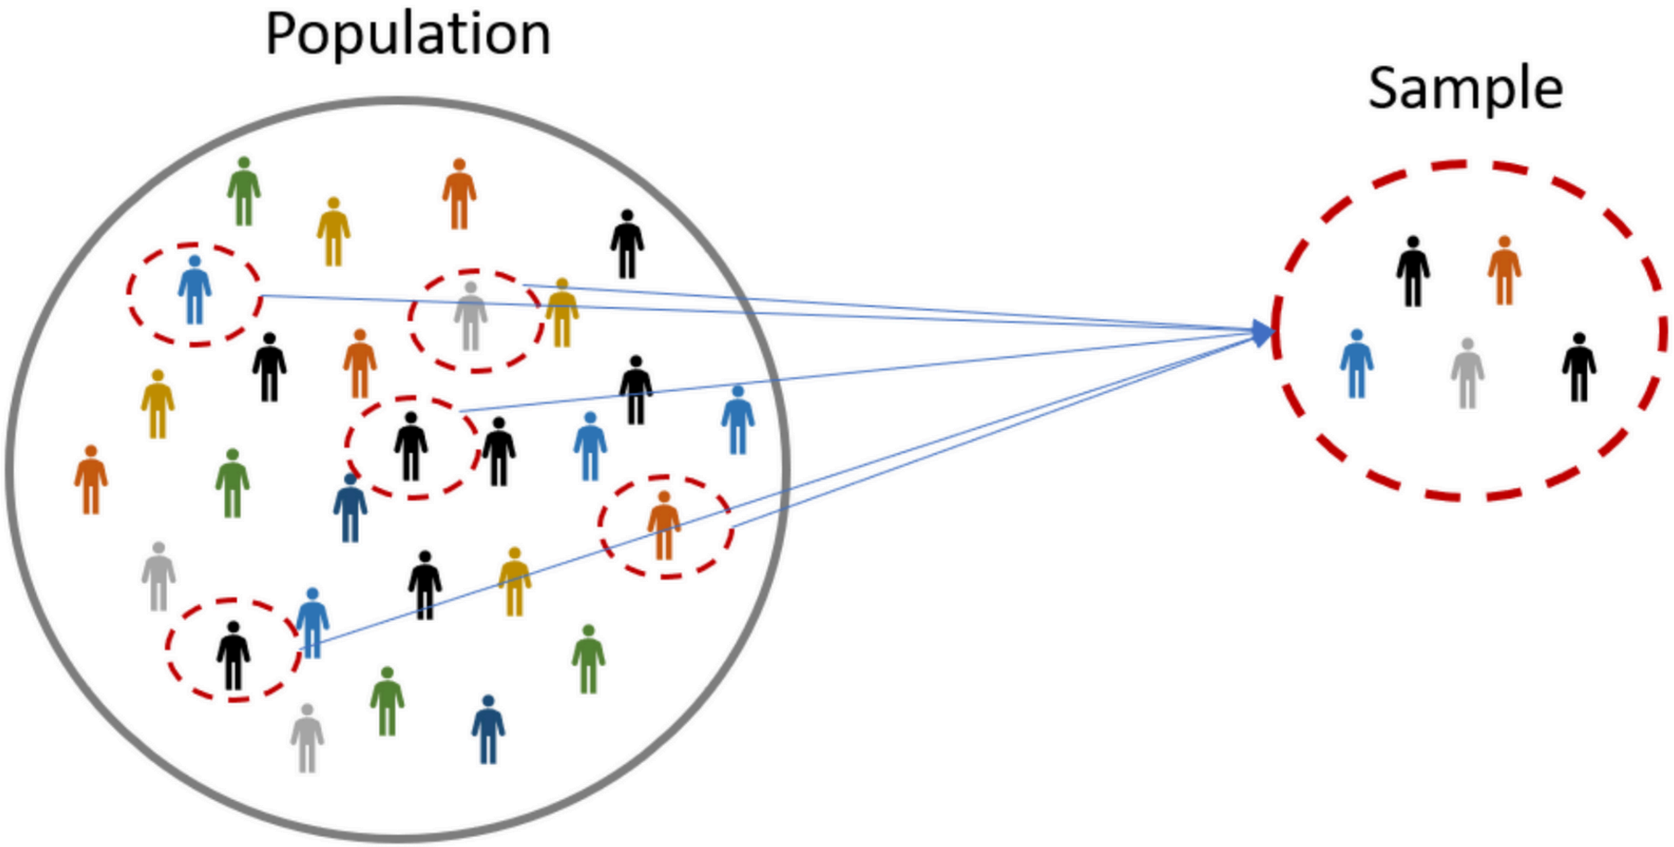

Geographical
Transport
Cultural
Natural
?
Scientific
Types of Data
Meteorological
$
Financial
Statistical


우리가 제일 잘 알고 있는 데이터?!

텐서!

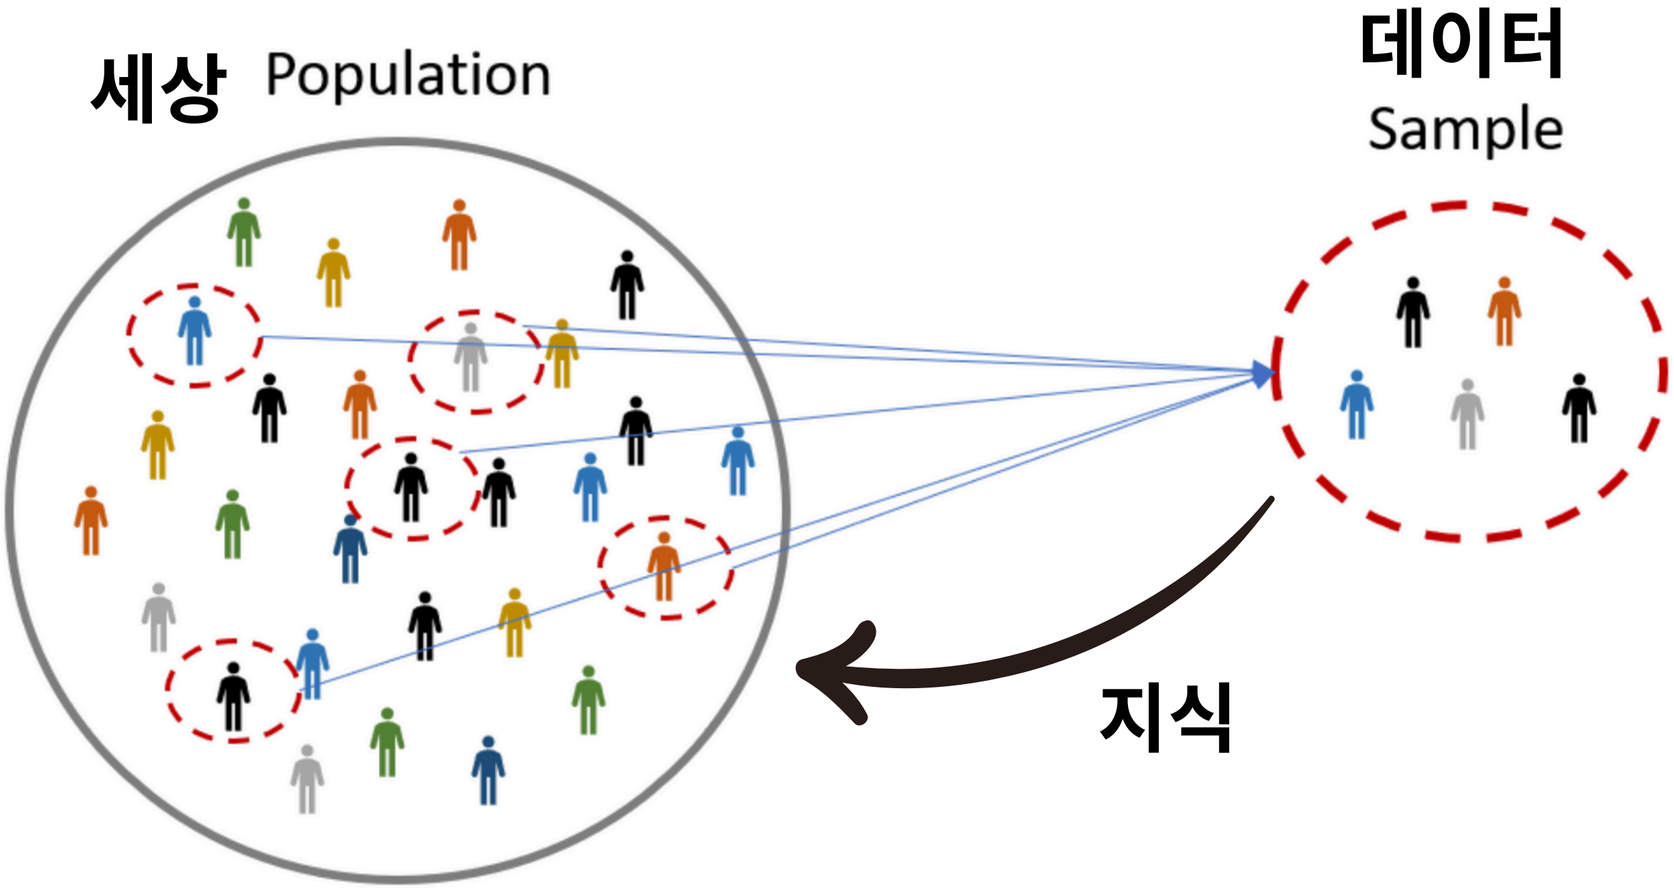


데이터란?



세상에 존재하는, 우리가 원하는 데이터를 모아요! 왜죠?

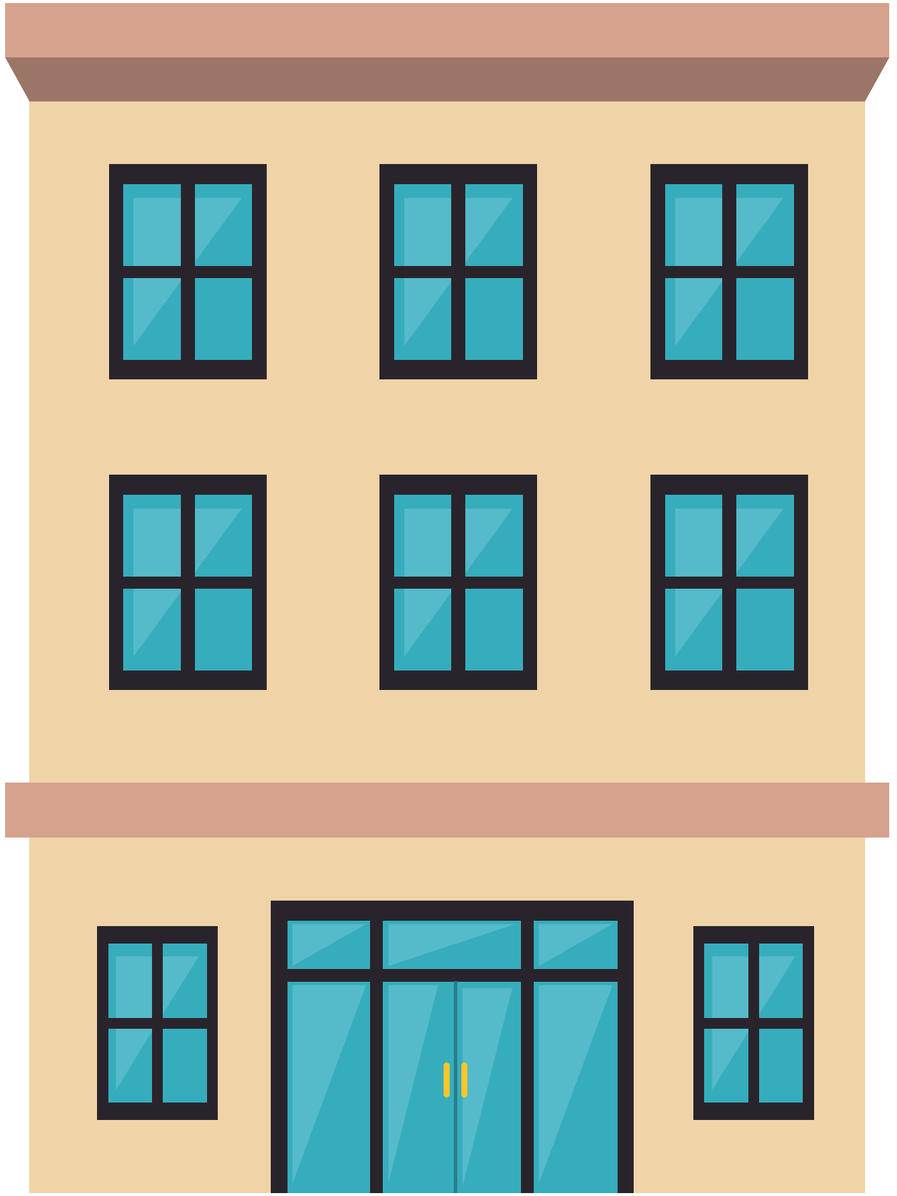
데이터란!



세상을 예측하고 싶기 때문입니다!

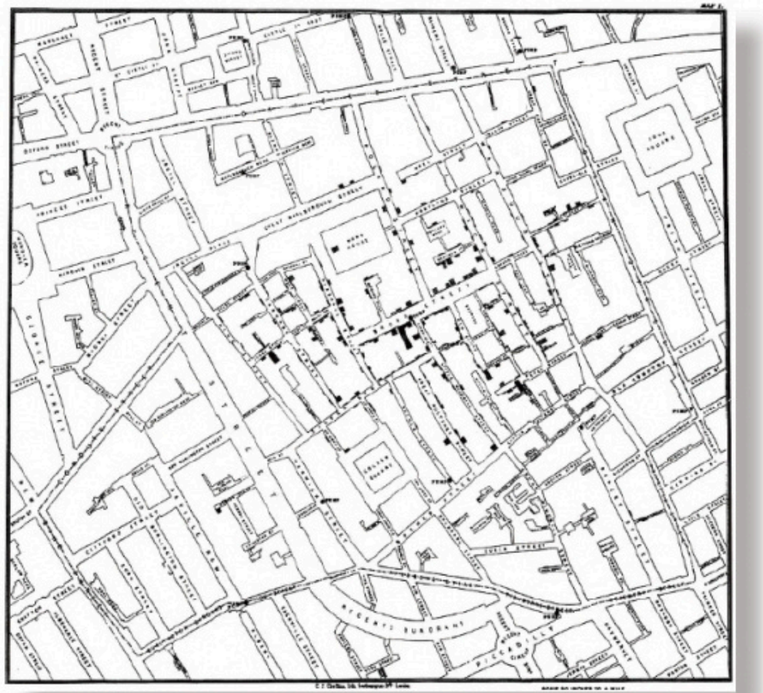
티라노사우루스는 키가 *7~8M*이고
머리둘레가 *2M* 정도 된다..





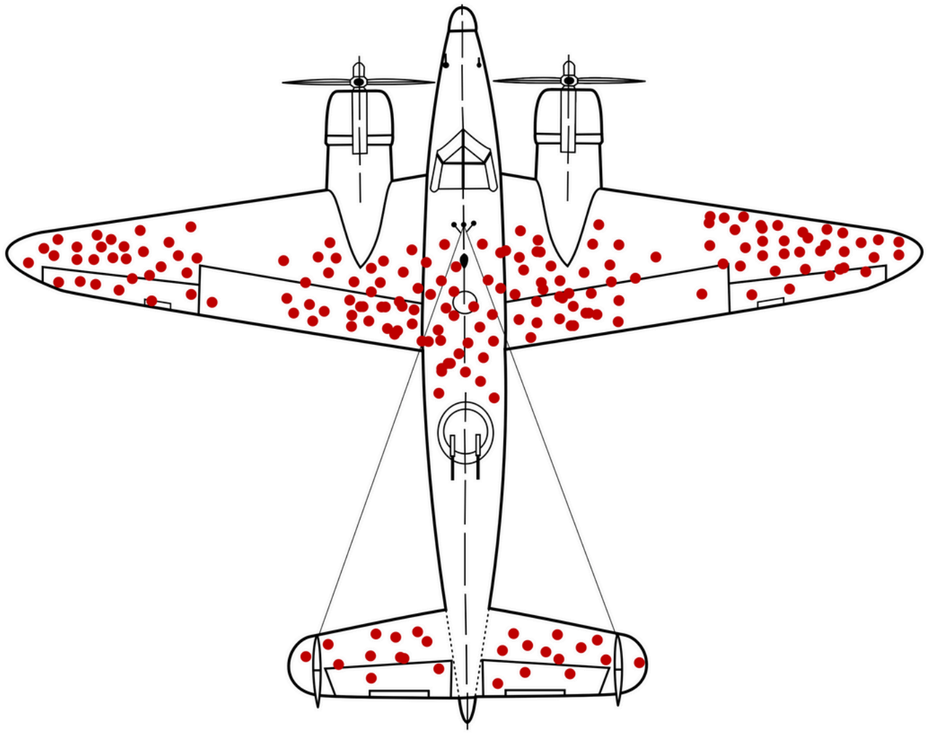
리처드 파인만 인터뷰 중에서..

〈그림 2〉 스노우가 만든 지도. 검은색 막대로 사망자의 수를 표시

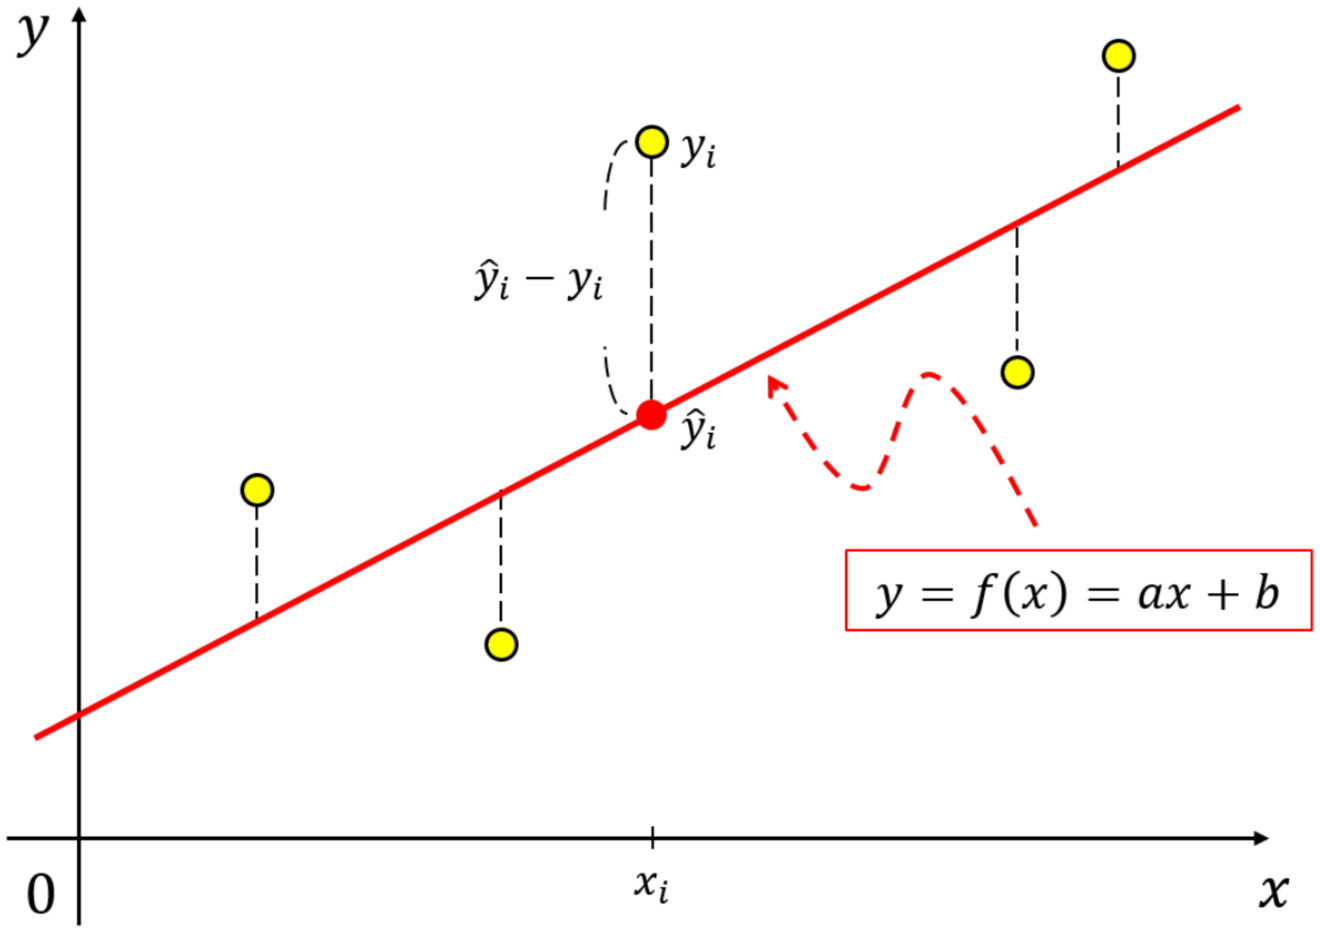


※ 자료: Wikipedia

저 구역 사람들이 같은 물을 마심



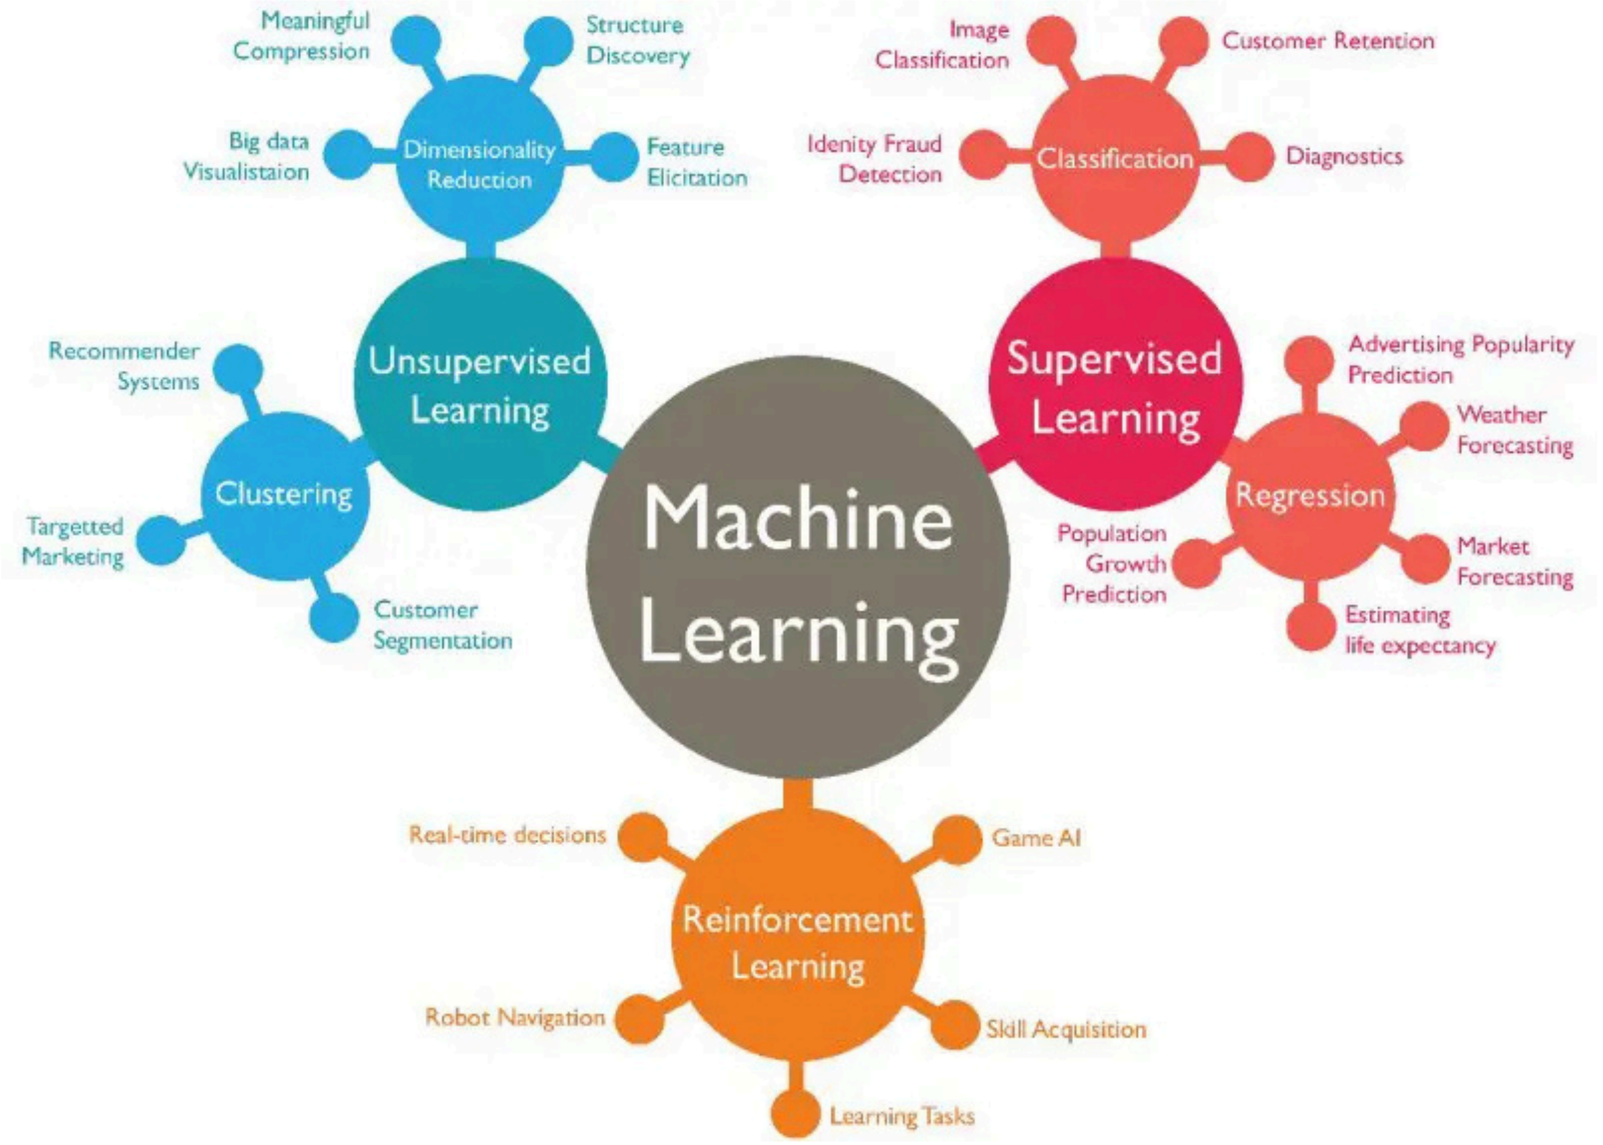
격납고의 비행기들 탄환 자국

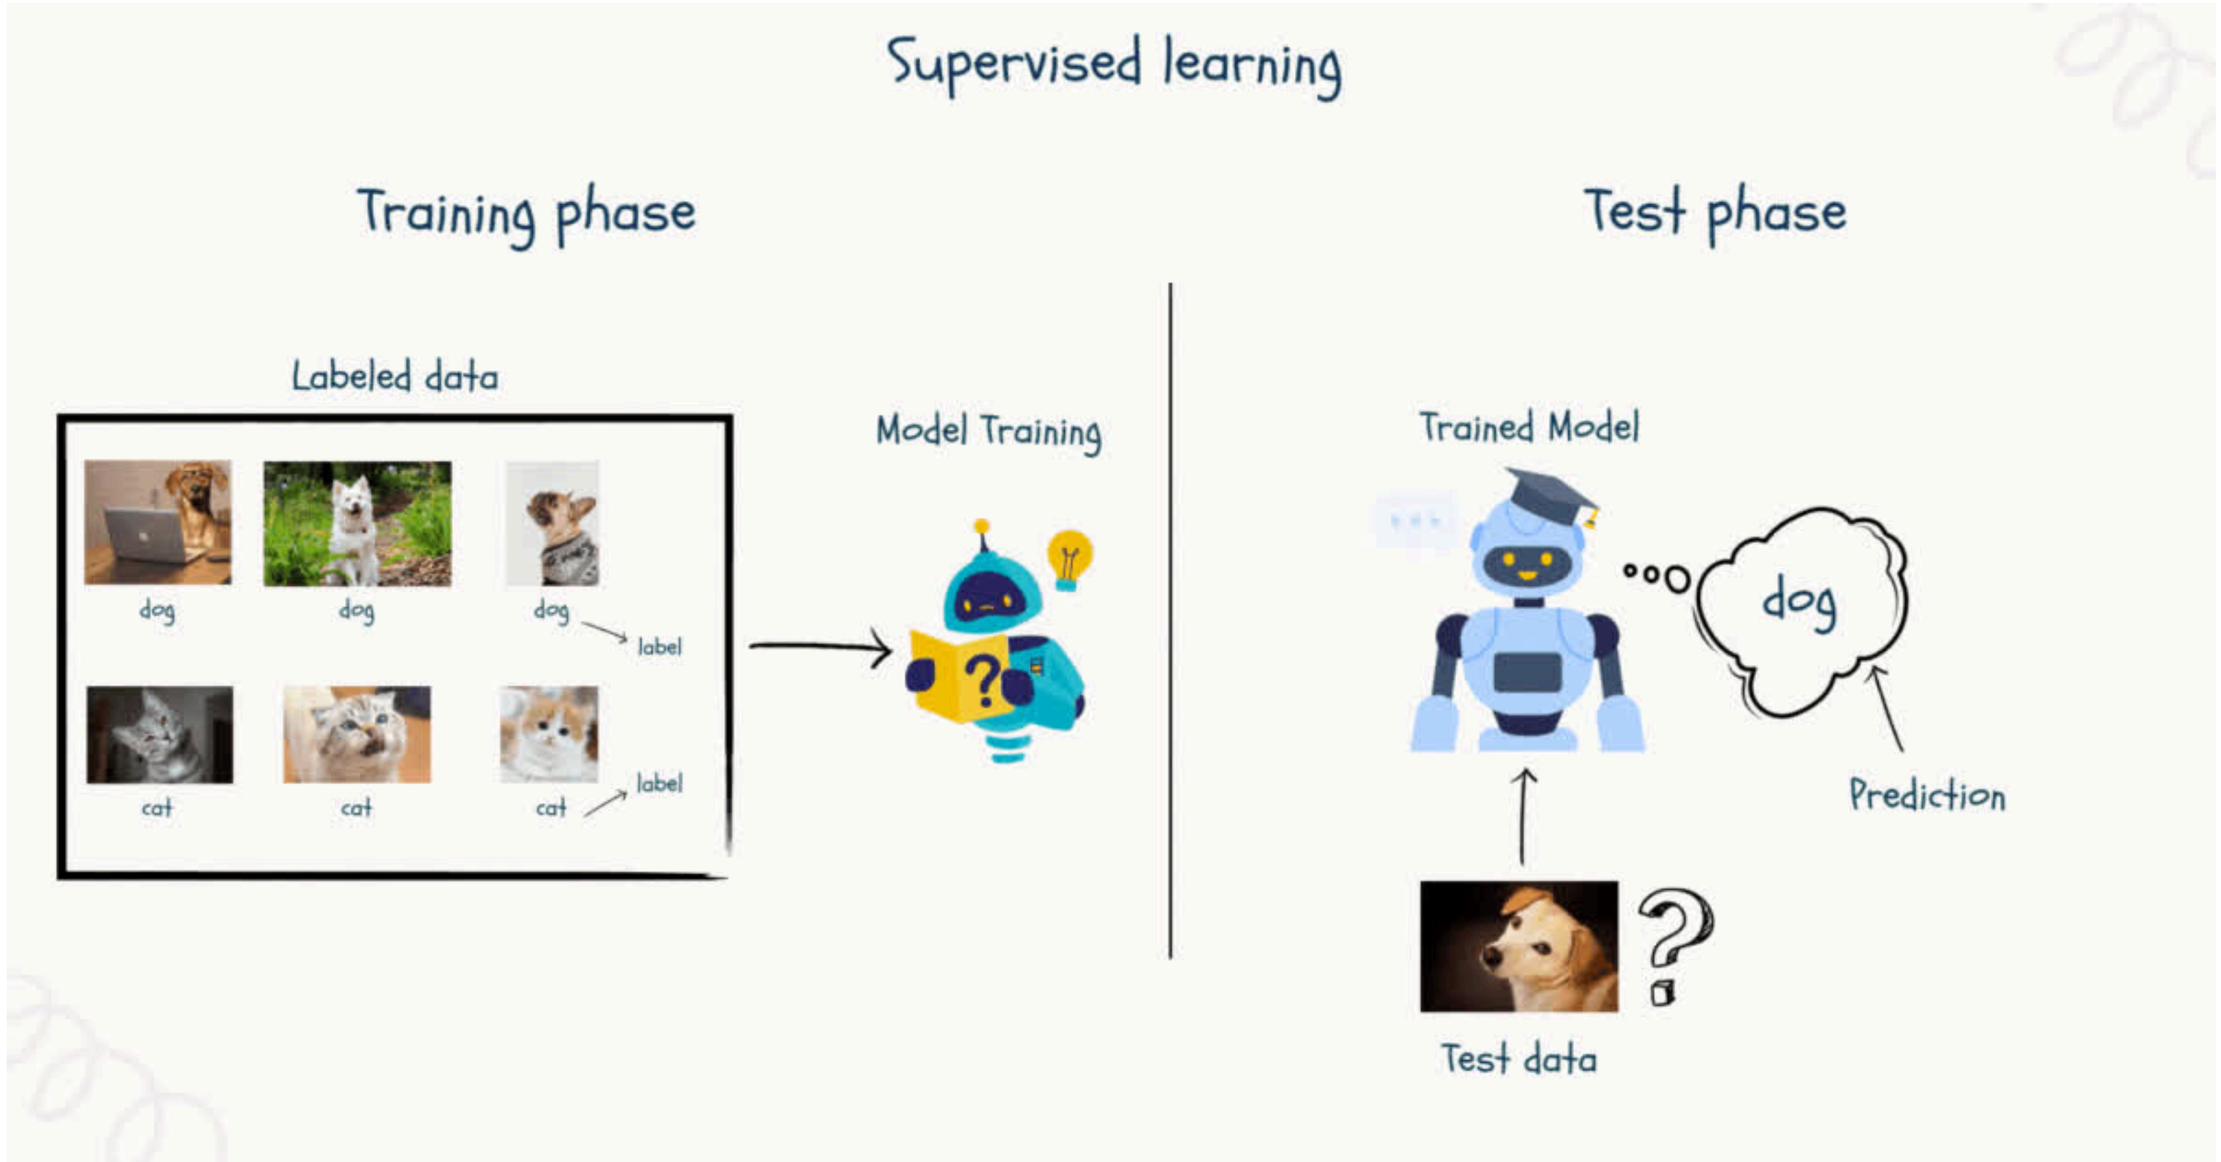


X,y?

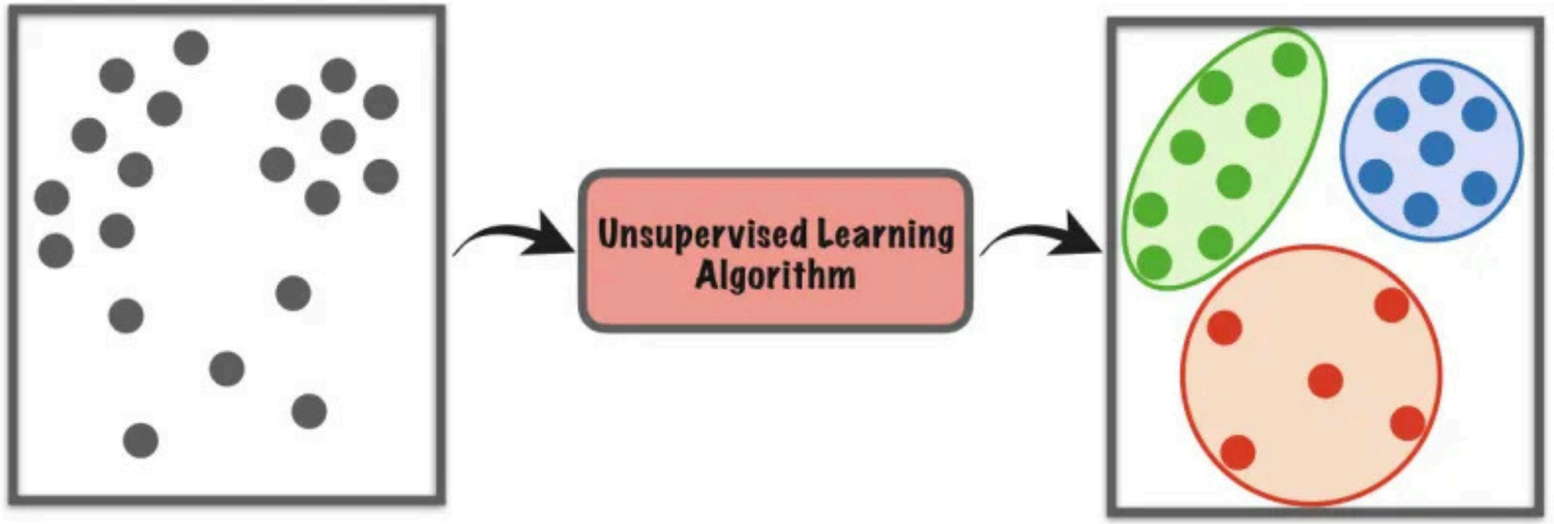
a,b?

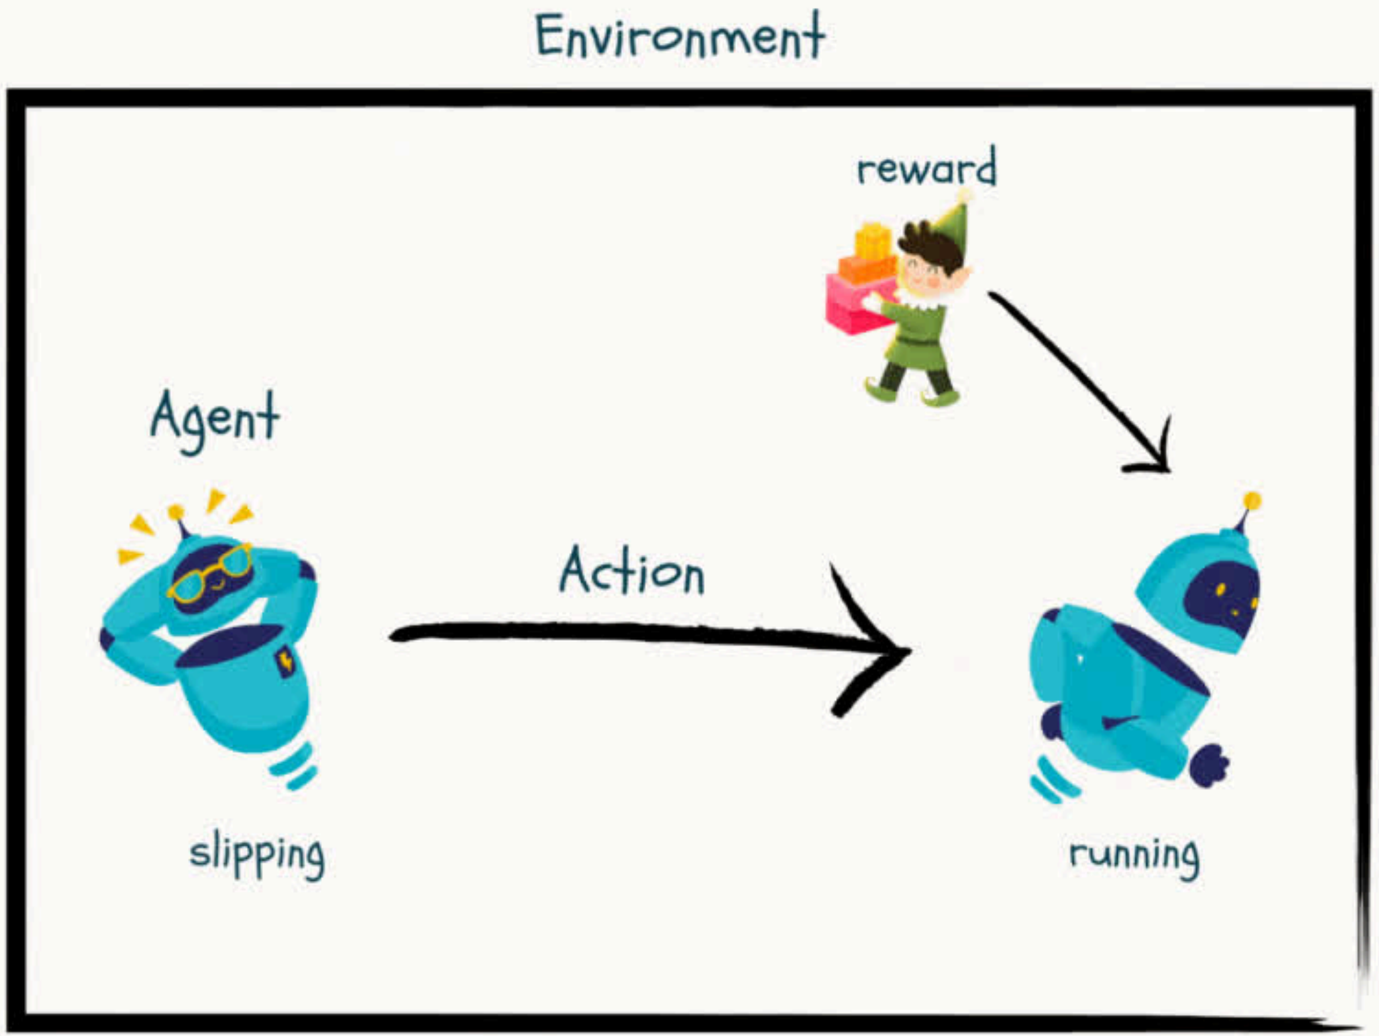
원하는 답을 찾기 위해!


Machine Learning
Unsupervised Learning
Dimensionality Reduction
Meaningful Compression
Structure Discovery
Big data Visualistaion
Feature Elicitation
Clustering
Recommender Systems
Targetted Marketing
Customer Segmentation
Supervised Learning
Classification
Image Classification
Customer Retention
Idenity Fraud Detection
Diagnostics
Regression
Advertising Popularity Prediction
Weather Forecasting
Market Forecasting
Estimating life expectancy
Population Growth Prediction
Reinforcement Learning
Real-time decisions
Game AI
Robot Navigation
Skill Acquisition
Learning Tasks



HTTPS://MEDIUM.COM/@BENSALEMH300/SUPERVISED-VS-UNSUPERVISED-VS-REINFORCEMENT-LEARNING-A3E7BCF1DD23

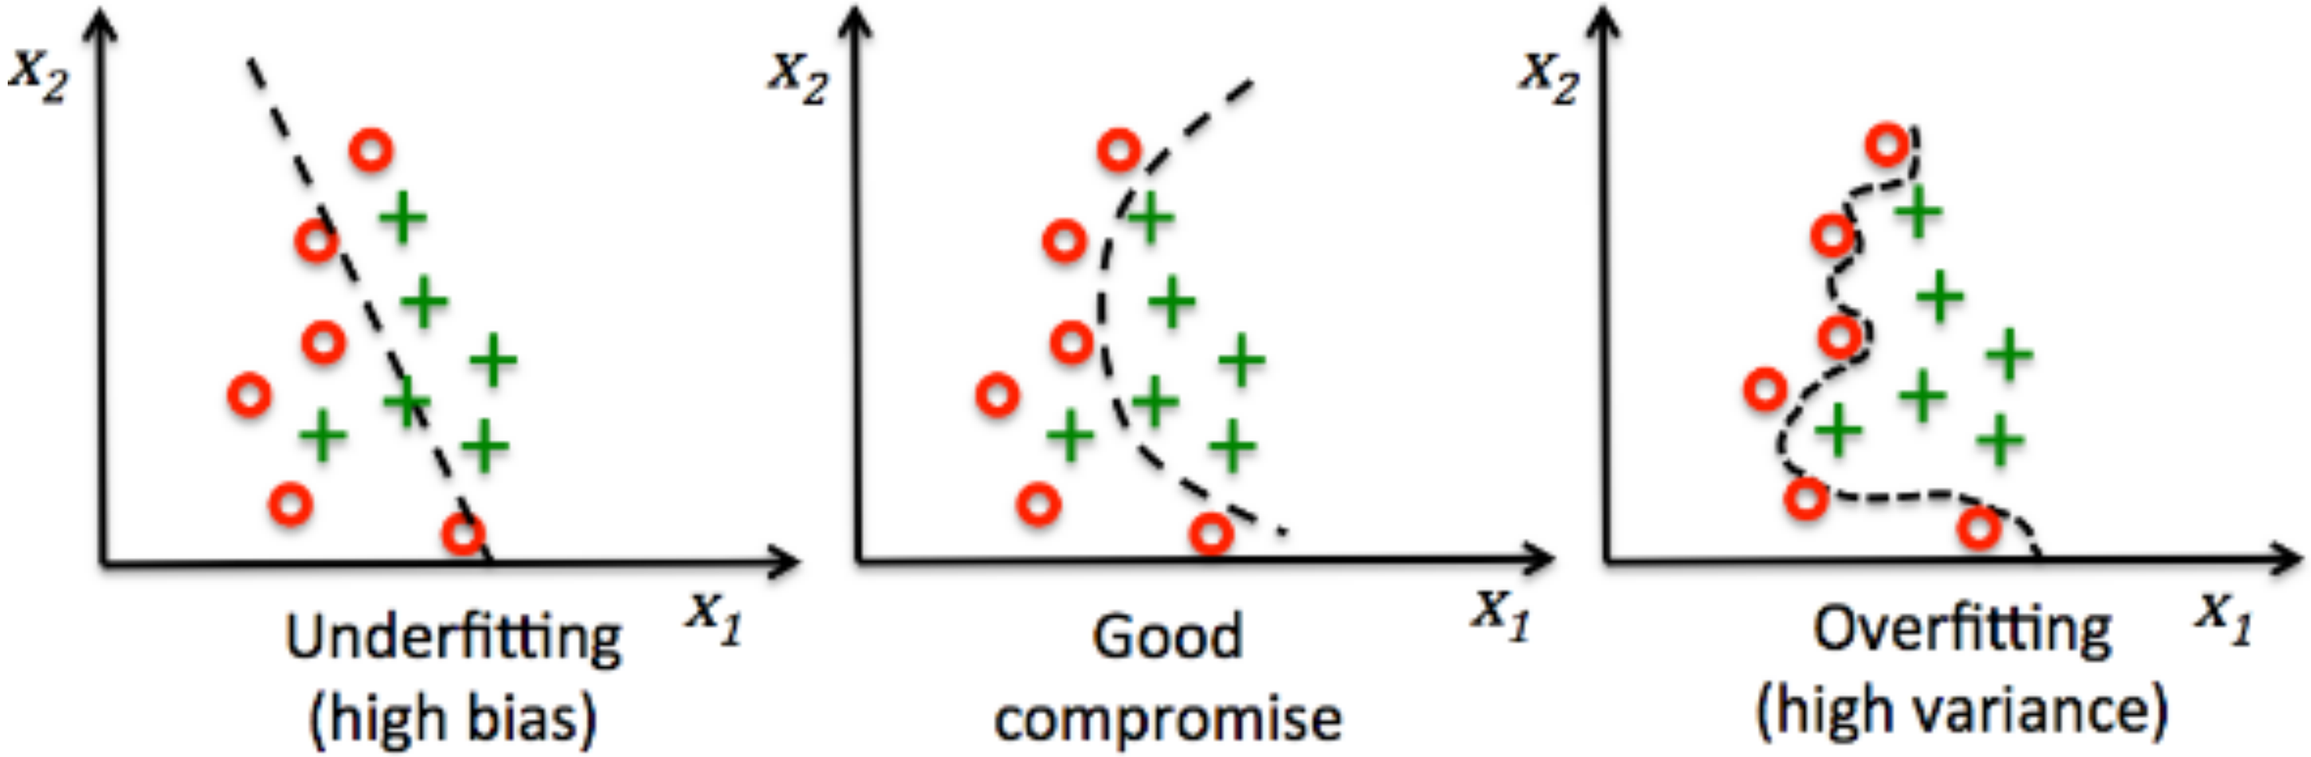

Unsupervised Learning
Algorithm


Environment
reward
Agent
Action
slipping
running

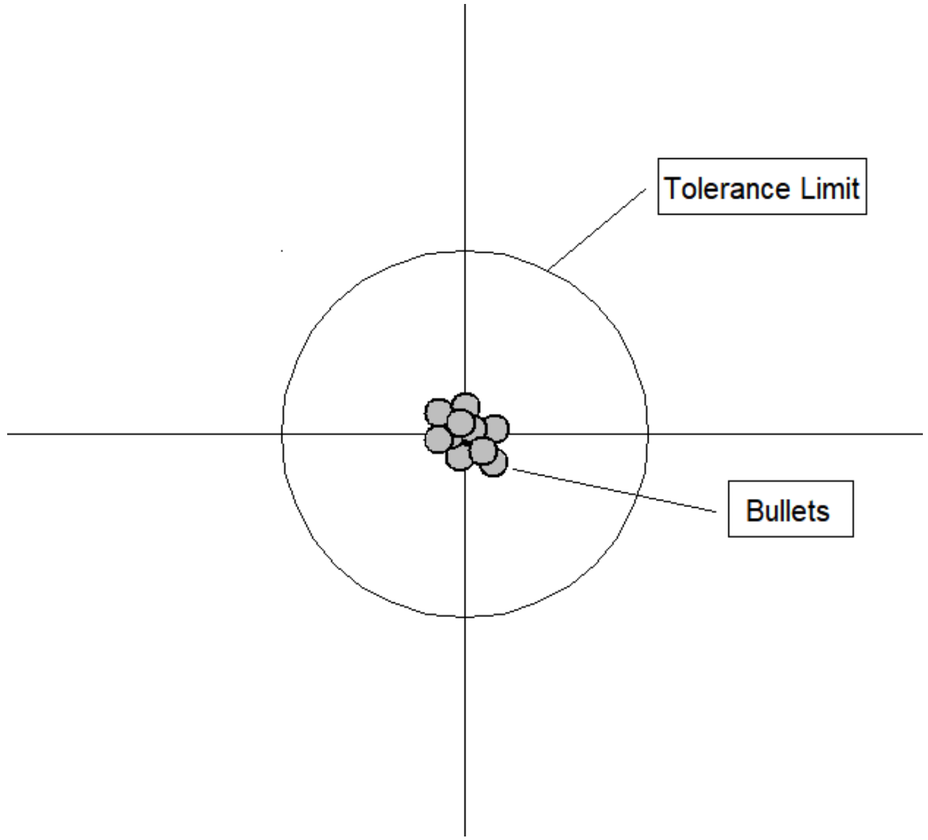
KNN

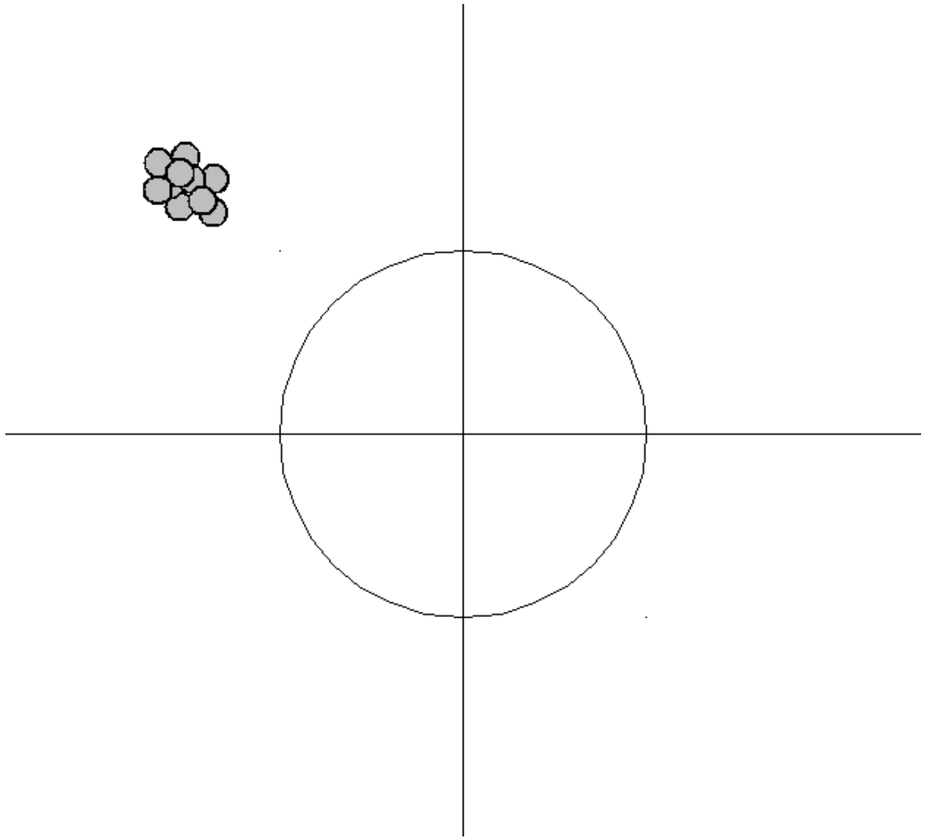
강인한 모델을 만드려면?

CLASSIFICATION

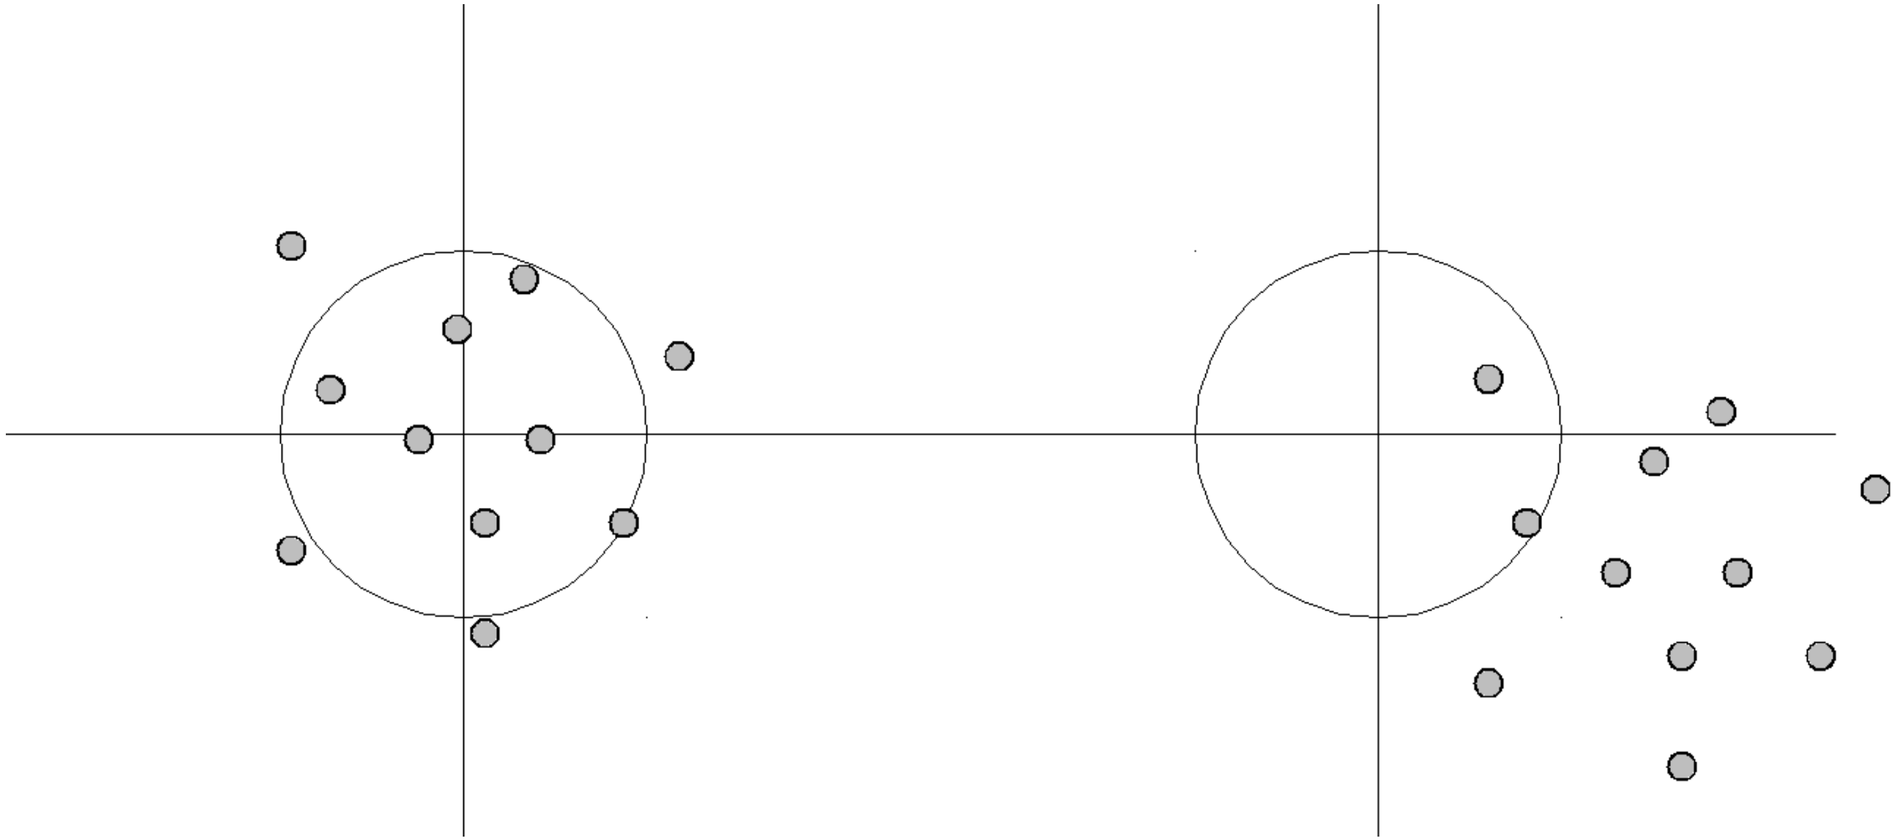


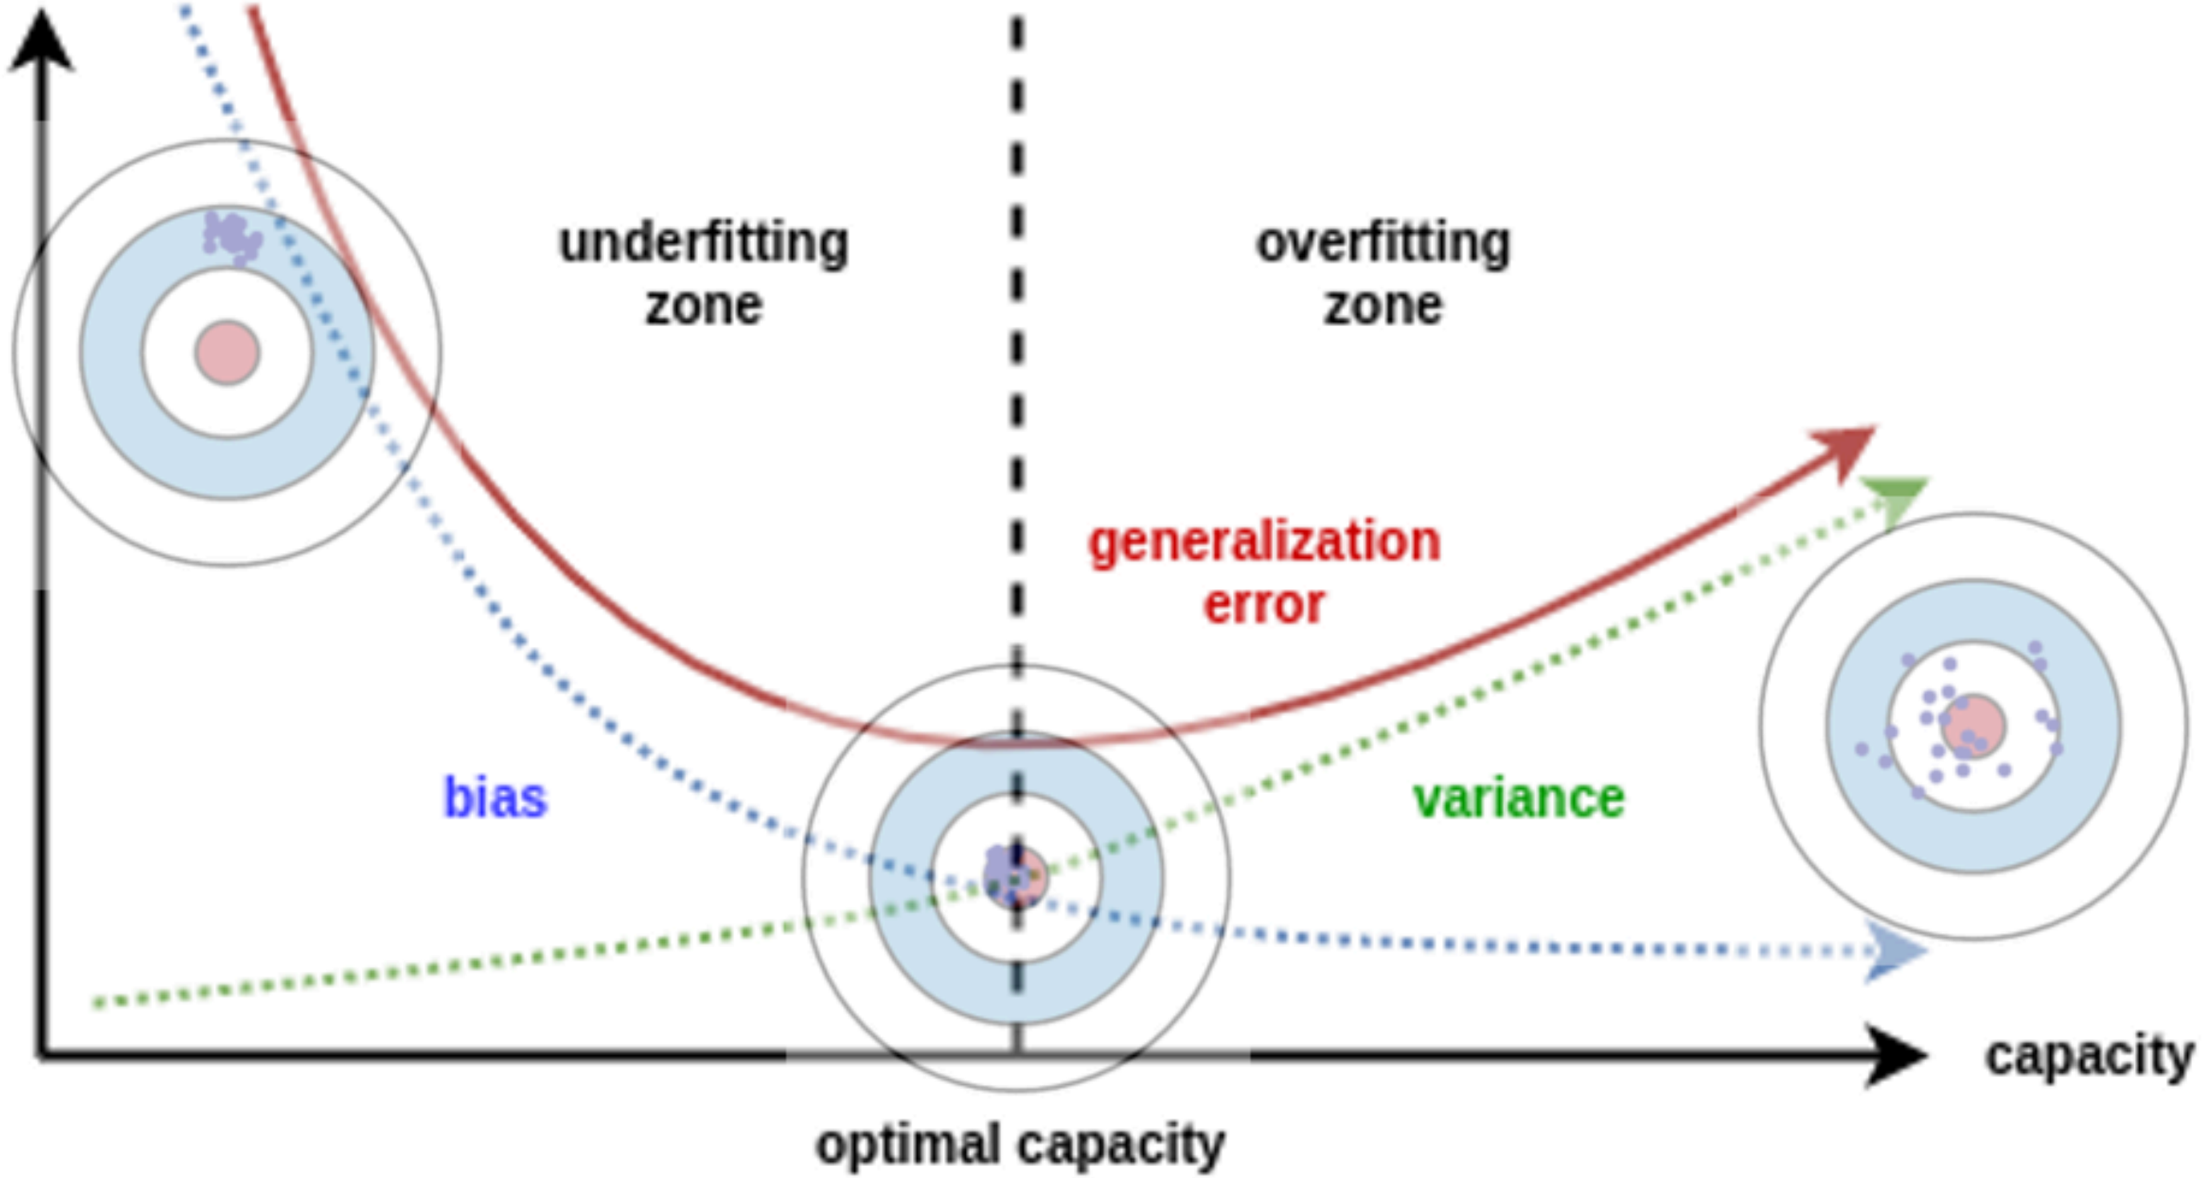
Bias vs Variance





Bias vs Variance





HTTPS://GAUSSIAN37.GITHUB.IO/MACHINE-LEARNING-CONCEPT-BIAS_AND_VARIANCE/

공부해야죠.

어떻게 Learning?

여러분의 공부는 어떤가요?



HTTPS://DAVINCILABS.AI/BLOG/?Q=YTOYONTZOJEYOIJRZXL3B3JKX3R5CGUIO3M6MZOIYWXSIJTZOJQ6INBHZ2UIO2K6MZT9&BMODE=VIEW&IDX=10608836&T=BOARD

Machine Learning?

기계는 어떻게 공부할까요?



HTTPS://DAVINCILABS.AI/BLOG/?Q=YTOYONTZOJEYOIJRZXL3B3JKX3R5CGUIO3M6MZOIYWXSIJTZOJQ6INBHZ2UIO2K6MZT9&BMODE=VIEW&IDX=10608836&T=BOARD

Train? Valid? Test



Train set

실제 연습문제



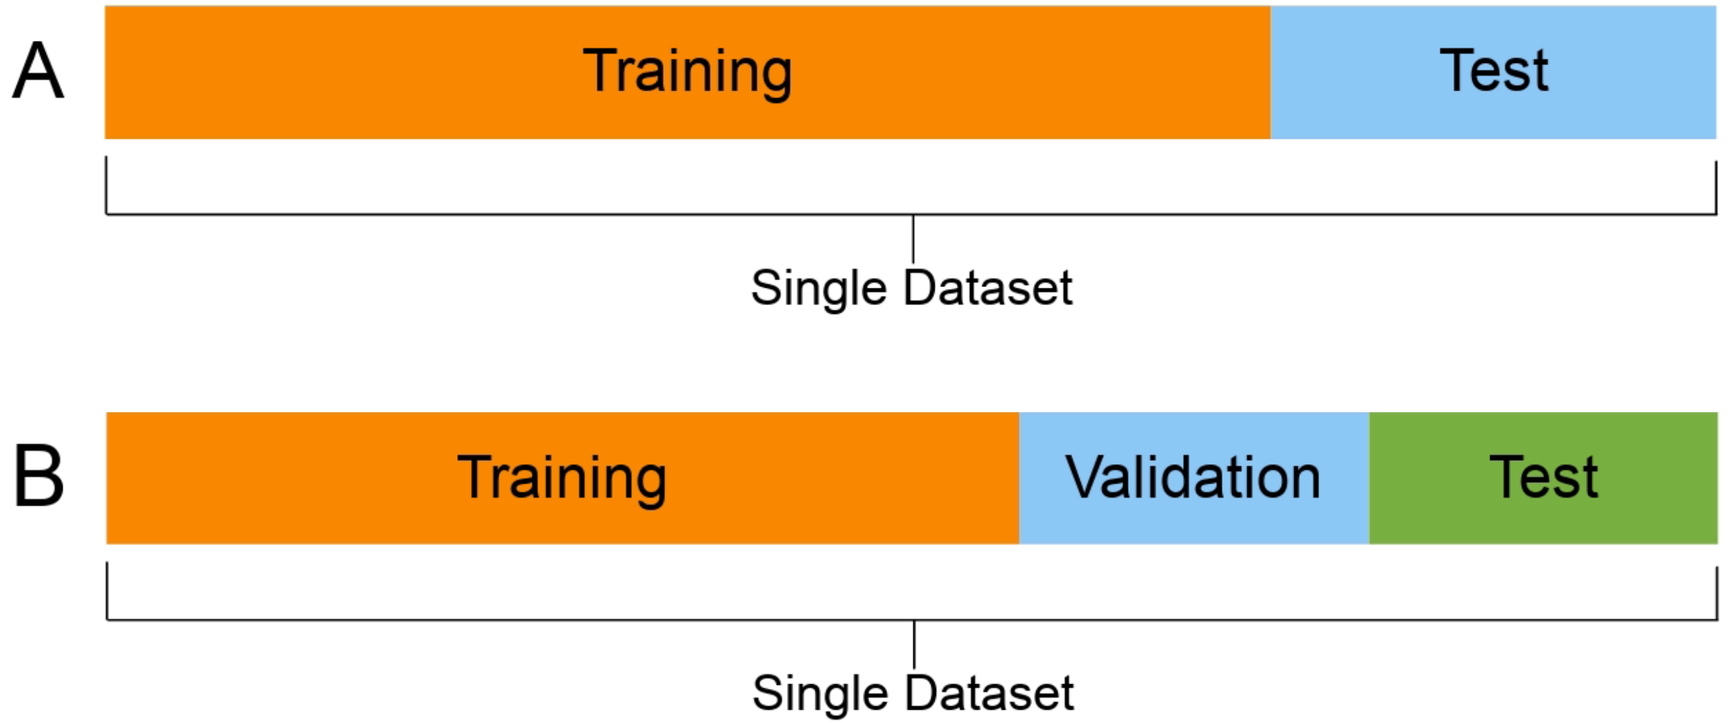
Valid set

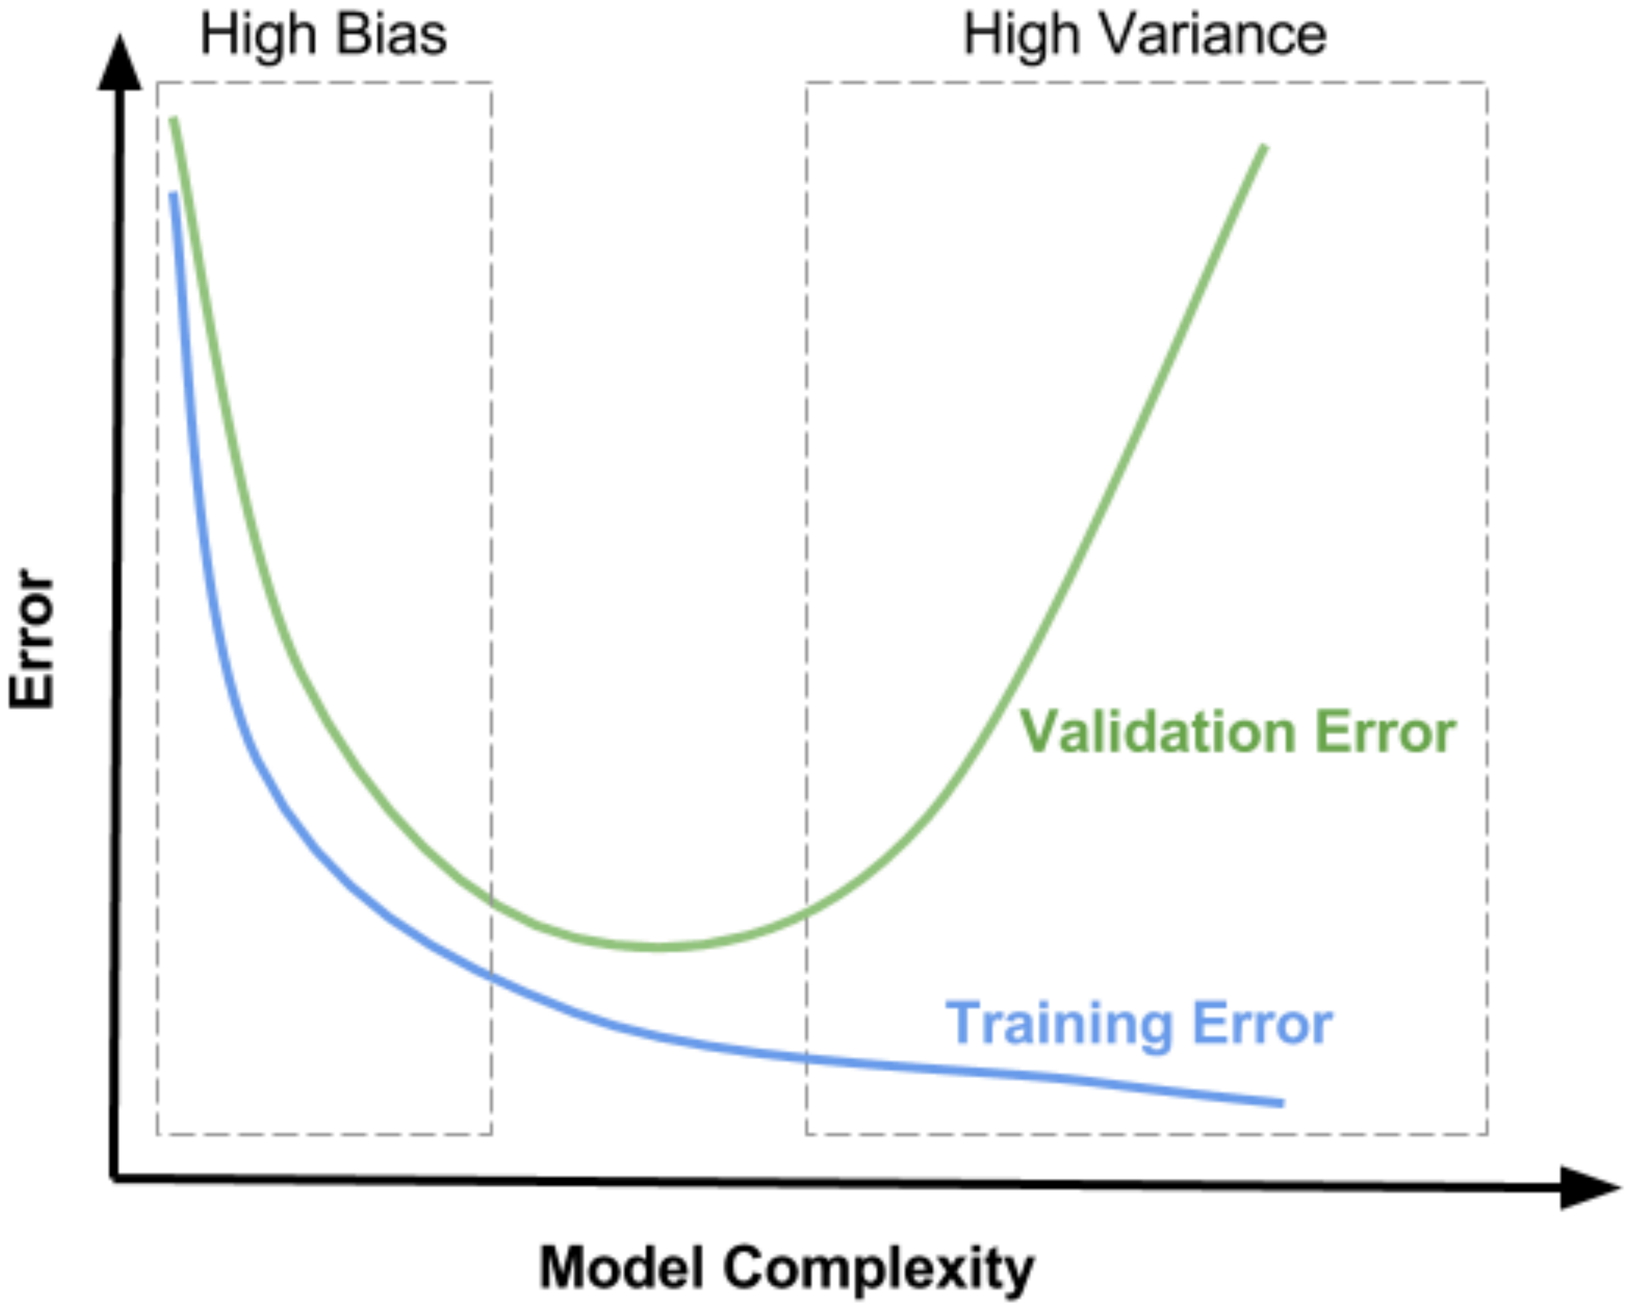
모의고사

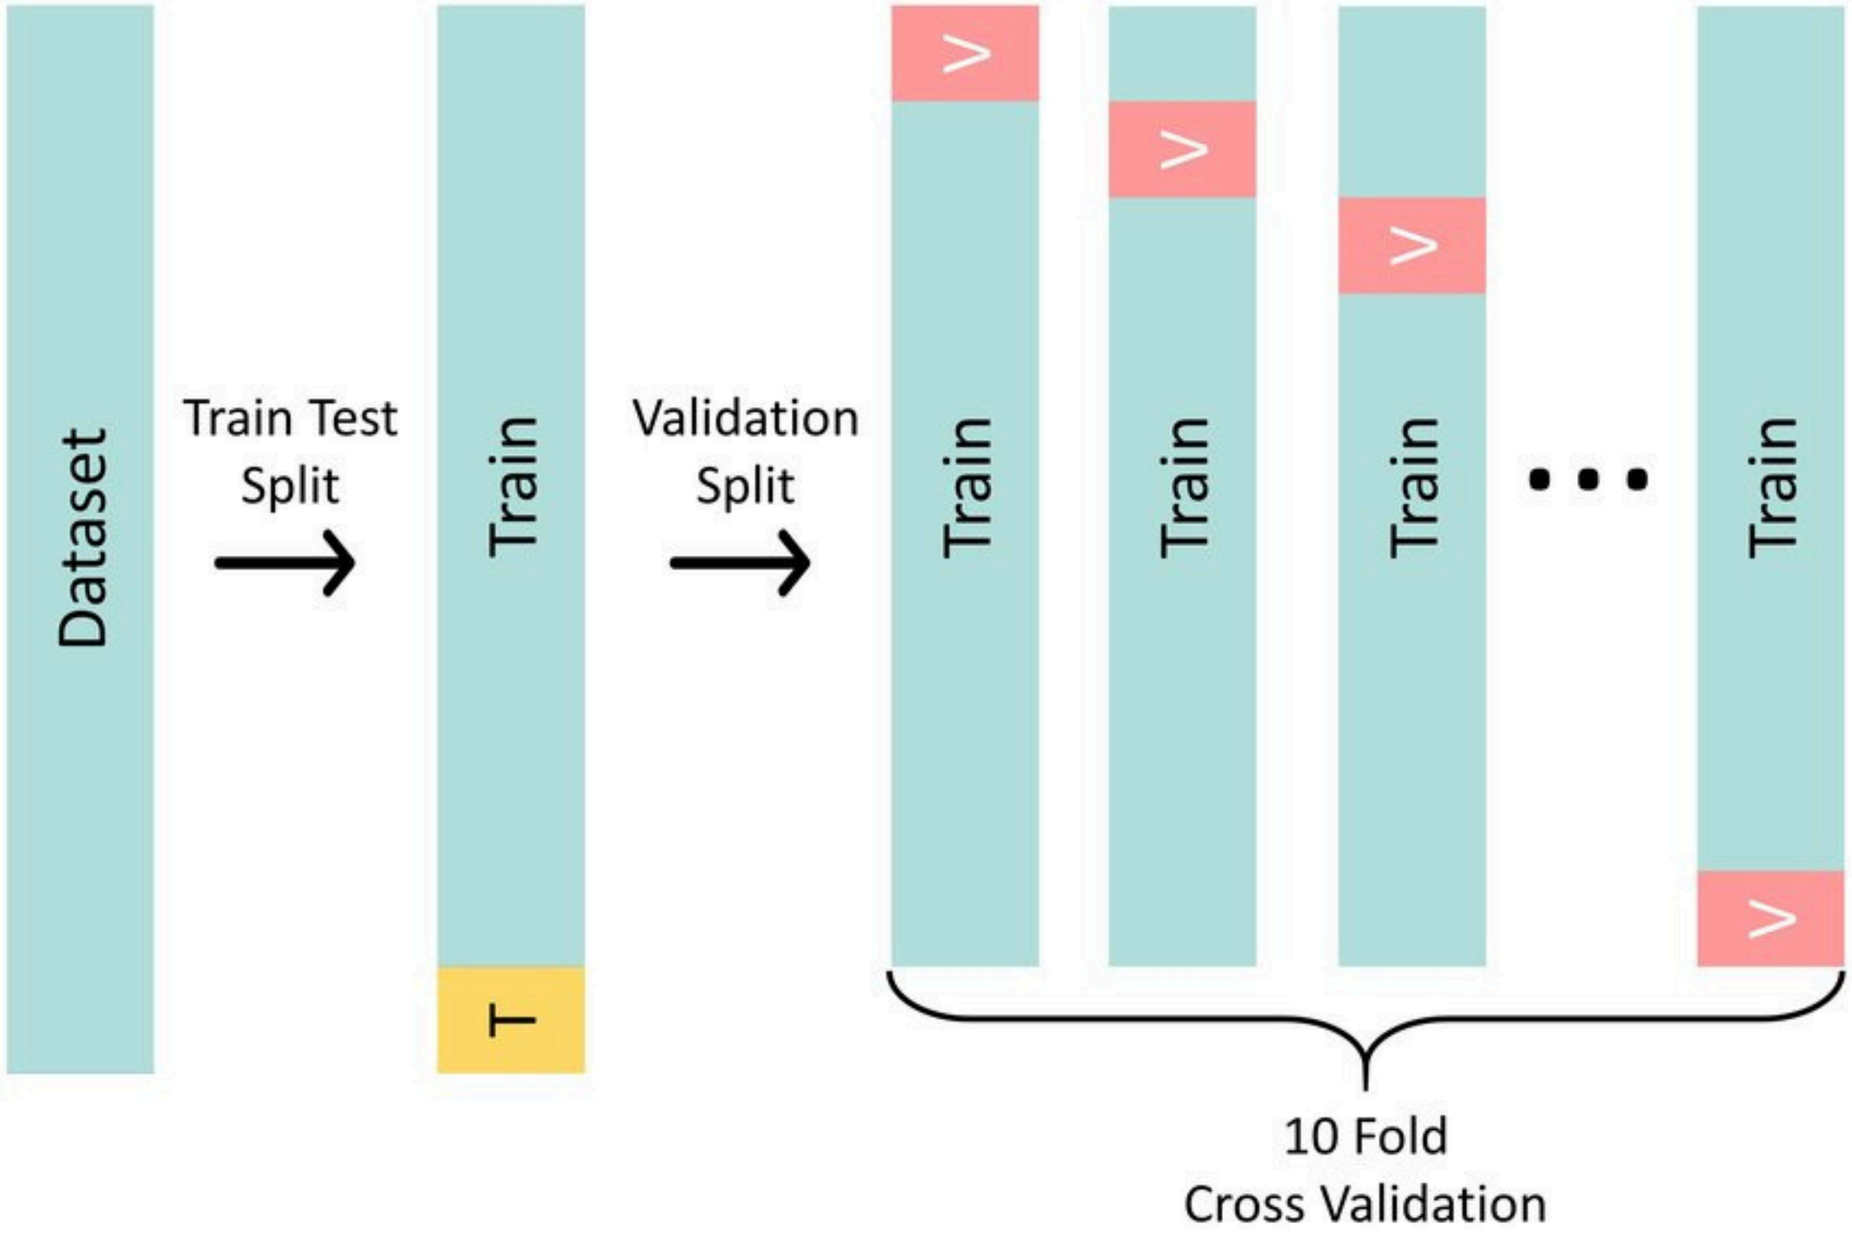


Test set

실제 시험


A
Training
Test
Single Dataset
B
Training
Validation
Test
Single Dataset


High Bias
High Variance
Error
Validation Error
Training Error
Model Complexity

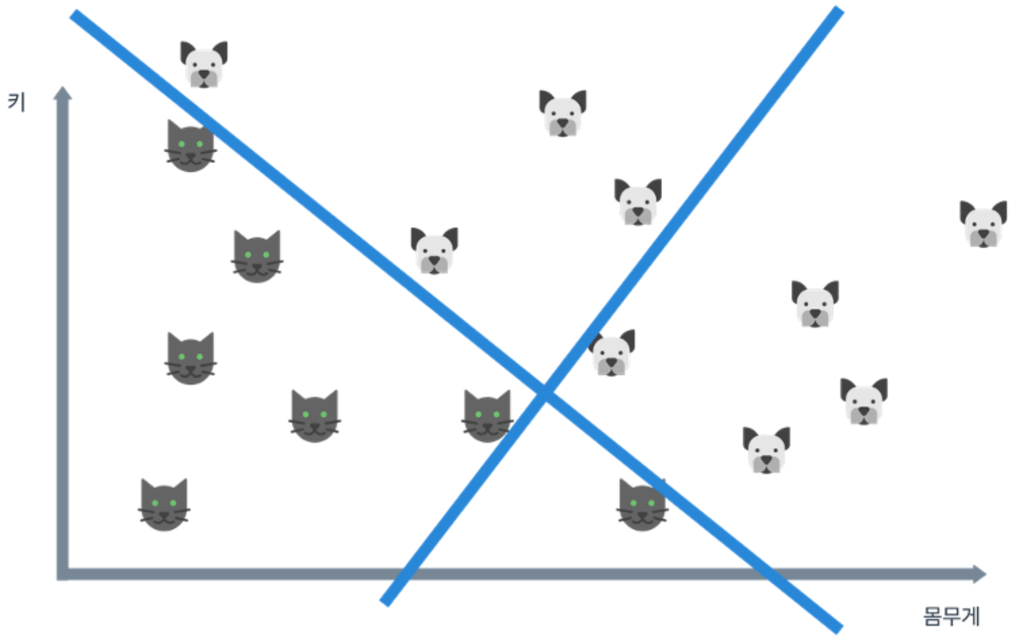

Dataset
Train Test Split
Train
T
Validation Split
Train
V
Train
V
Train
V
Train
V
10 Fold Cross Validation



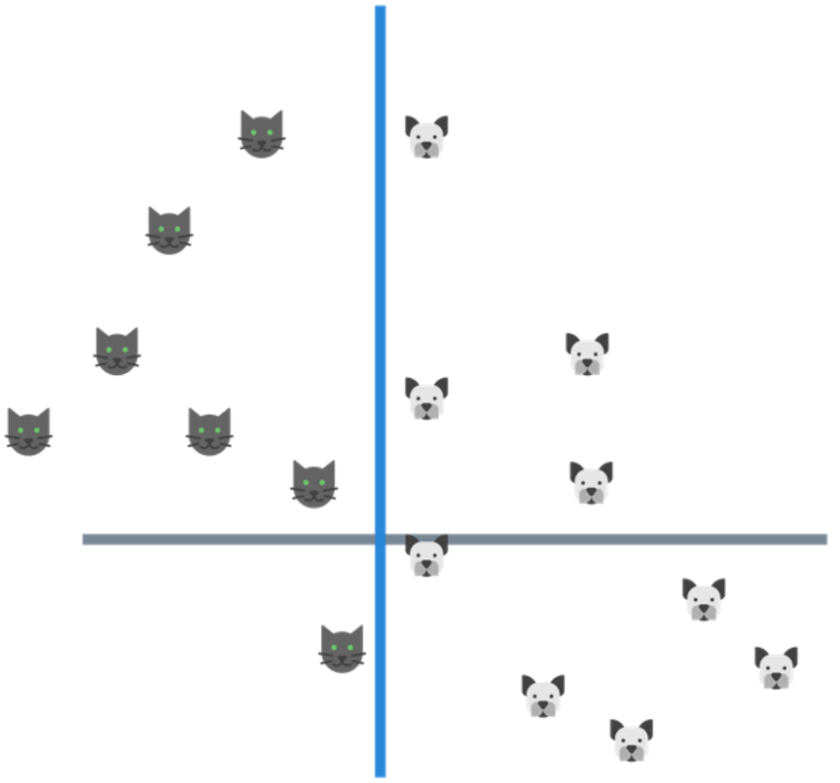
입력 **데이터**: (몸무게, 키) 좌표

기대 출력: 강아지인지 고양이인지의 여부

How?





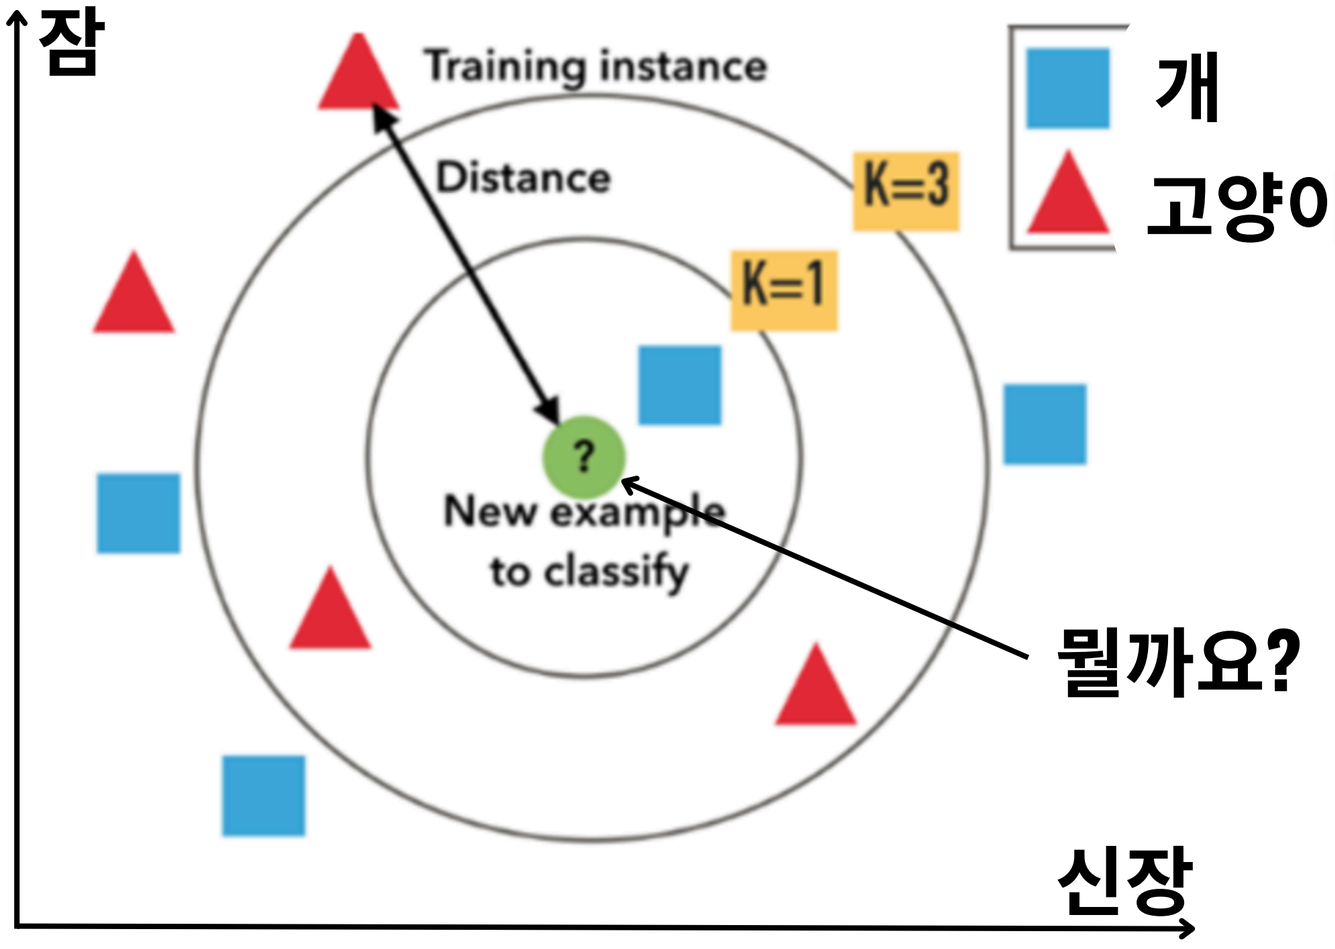


좌표변환,이동, projection 등의
가능한 연산을 자동으로 찾는 **'학습'**

더 좋은 표현을 찾으면, 새로운 데이터가 들어왔을 때
고양이인지 강아지인지 판별하기 쉽다!

K-Nearest Neighbour 알고리즘

Classification 문제



개

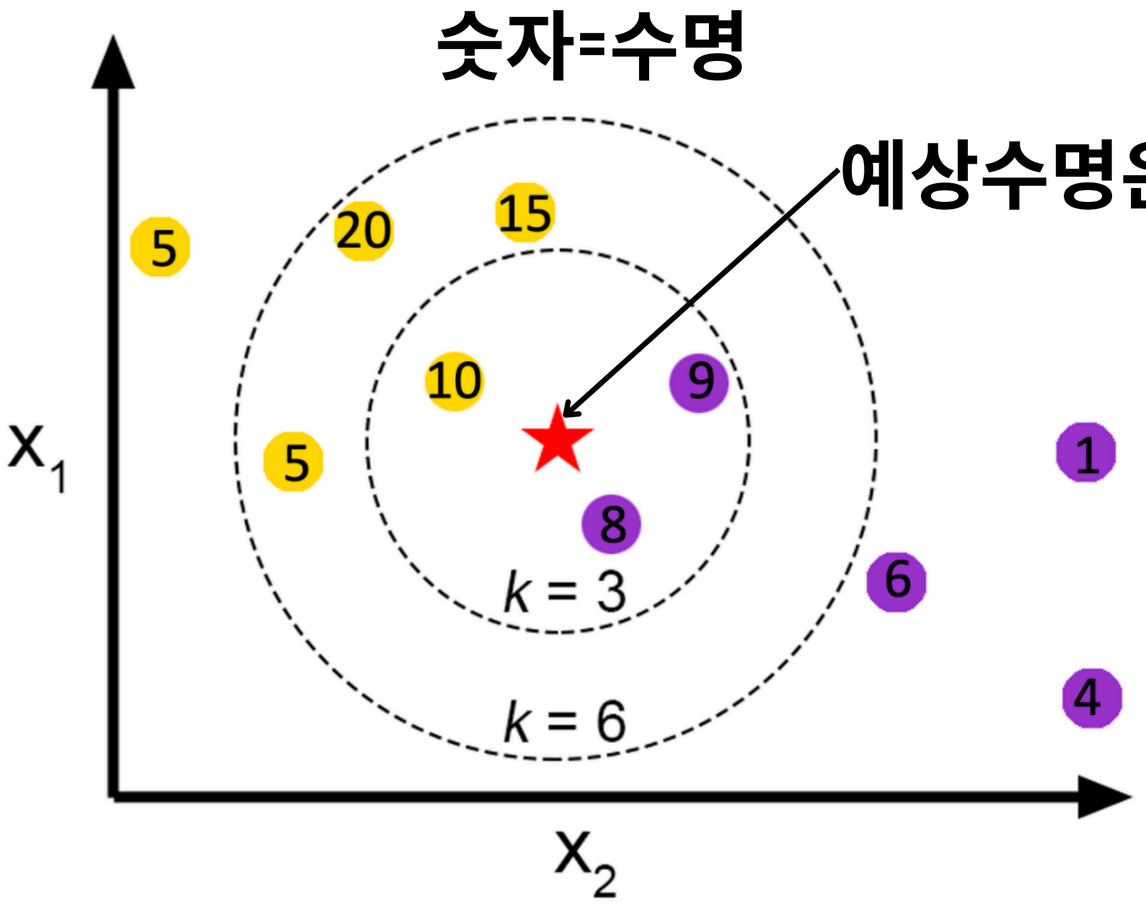
고양이

- 현재 위치에서 K개 만큼의 가까운 이웃을 찾고 많은 쪽을 따라 가는것

- 얼마나 큰 K?
- 거리는 어떻게?
- 클래스가 여러개면?

K-nn regression

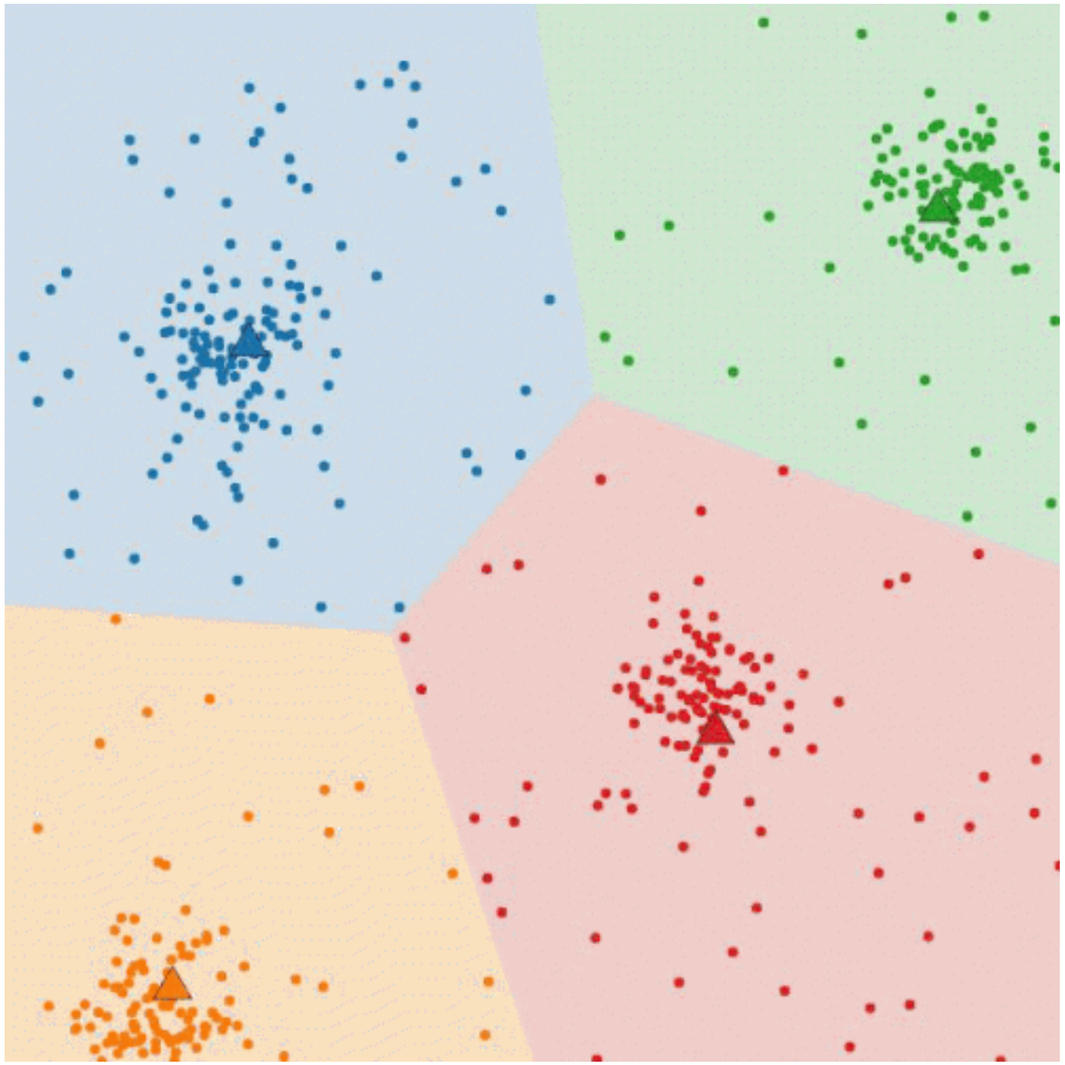
regression문제



- 만약 구분이 아니라 값을 예측하는 거라면?
- 마찬가지로 k개 만큼의 근접 이웃들을 찾고 그것의 평균
- 평균? 중간값?
- 거리는?

K-means clustering

1. 임의의 중심을 k개 만큼 위치
2. 모든 점을 가까운 중심에 배정
3. 같은 중심에 배정된 점들의 중심점을 찾아 새로운 중심으로 이동
4. 변경된 중심에 대해 다시 모든 점을 새로 배정
5. 수렴시까지 반복



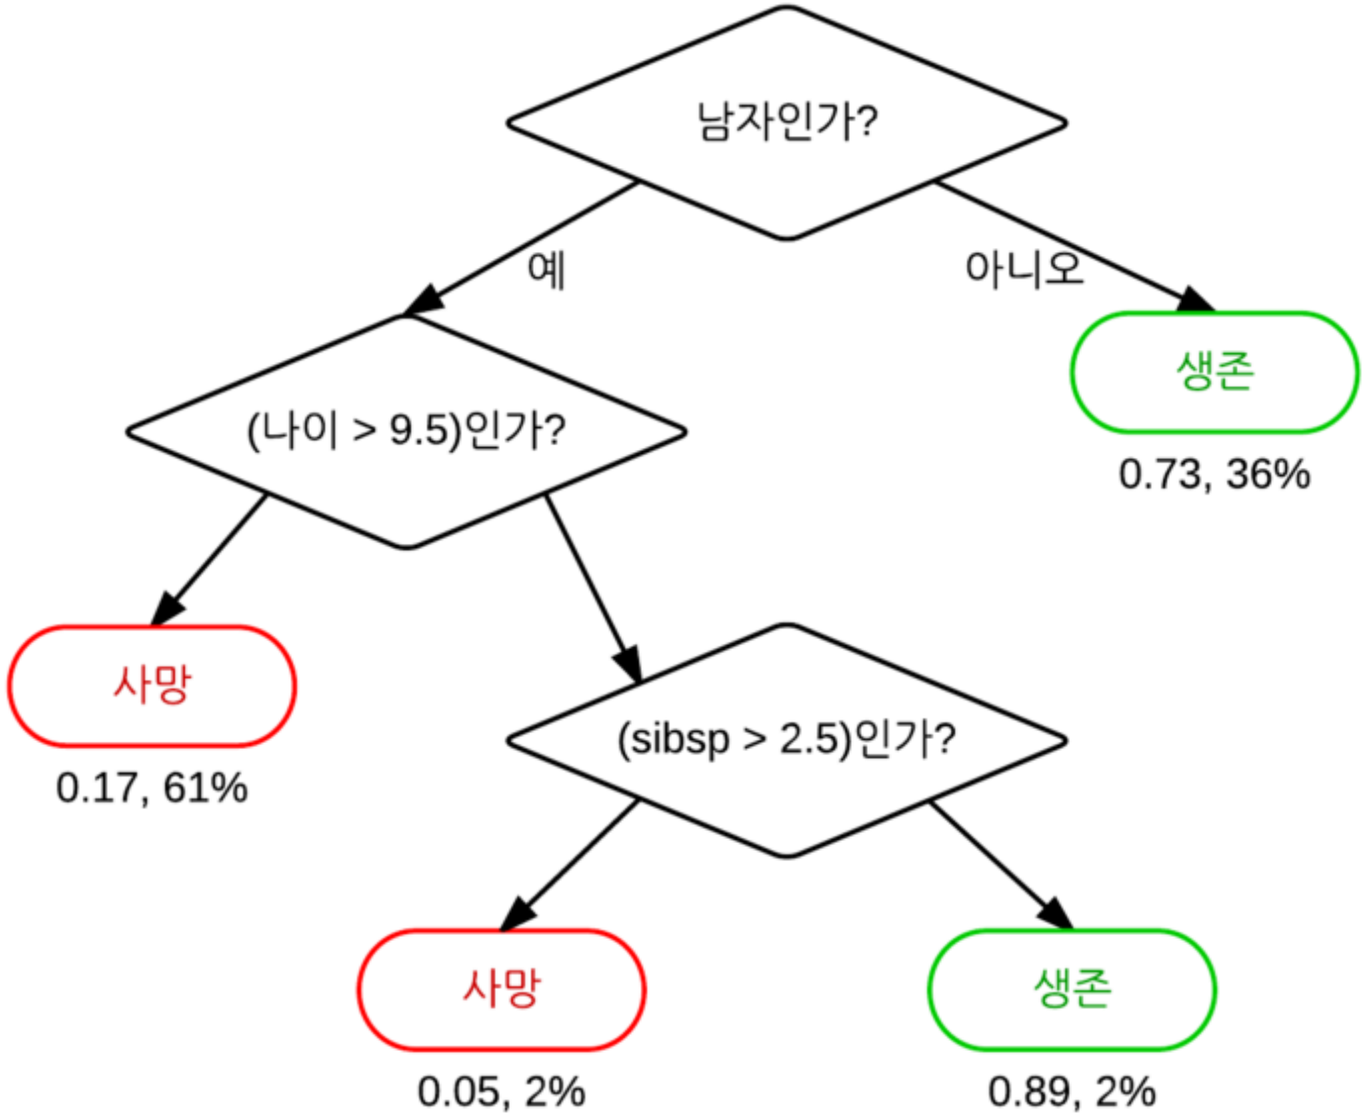
DECISION TREE

DECISION TREE 예시

타이타닉호 탑승객의 생존 여부를 나타내는 결정 트리.

(“sibsp”는 탑승한 배우자와 자녀의 수를 의미한다.)

잎 아래의 숫자는 각각 생존 확률과 탑승객이 그 잎에 해당될 확률을 의미한다.



HTTPS://KO.WIKIPEDIA.ORG/WIKI/%EA%B2%B0%EC%A0%95_%ED%8A%B8%EB%A6%AC_%ED%95%99%EC%8A%B5%EB%B2%95

“구분한다” = 같은 종류끼리 모인다

가공을 거칠수록 순도가 높아진다 = 불순도가 낮아진다

불순도를 정의해보자!

지니계수 $I(A) = 1 - \sum_{k=1}^{m} p_k^2$

엔트로피 $E = -\sum_{i=1}^{k} p_i \log_2(p_i)$

합 로그 확률(P)

불순도를 계산:



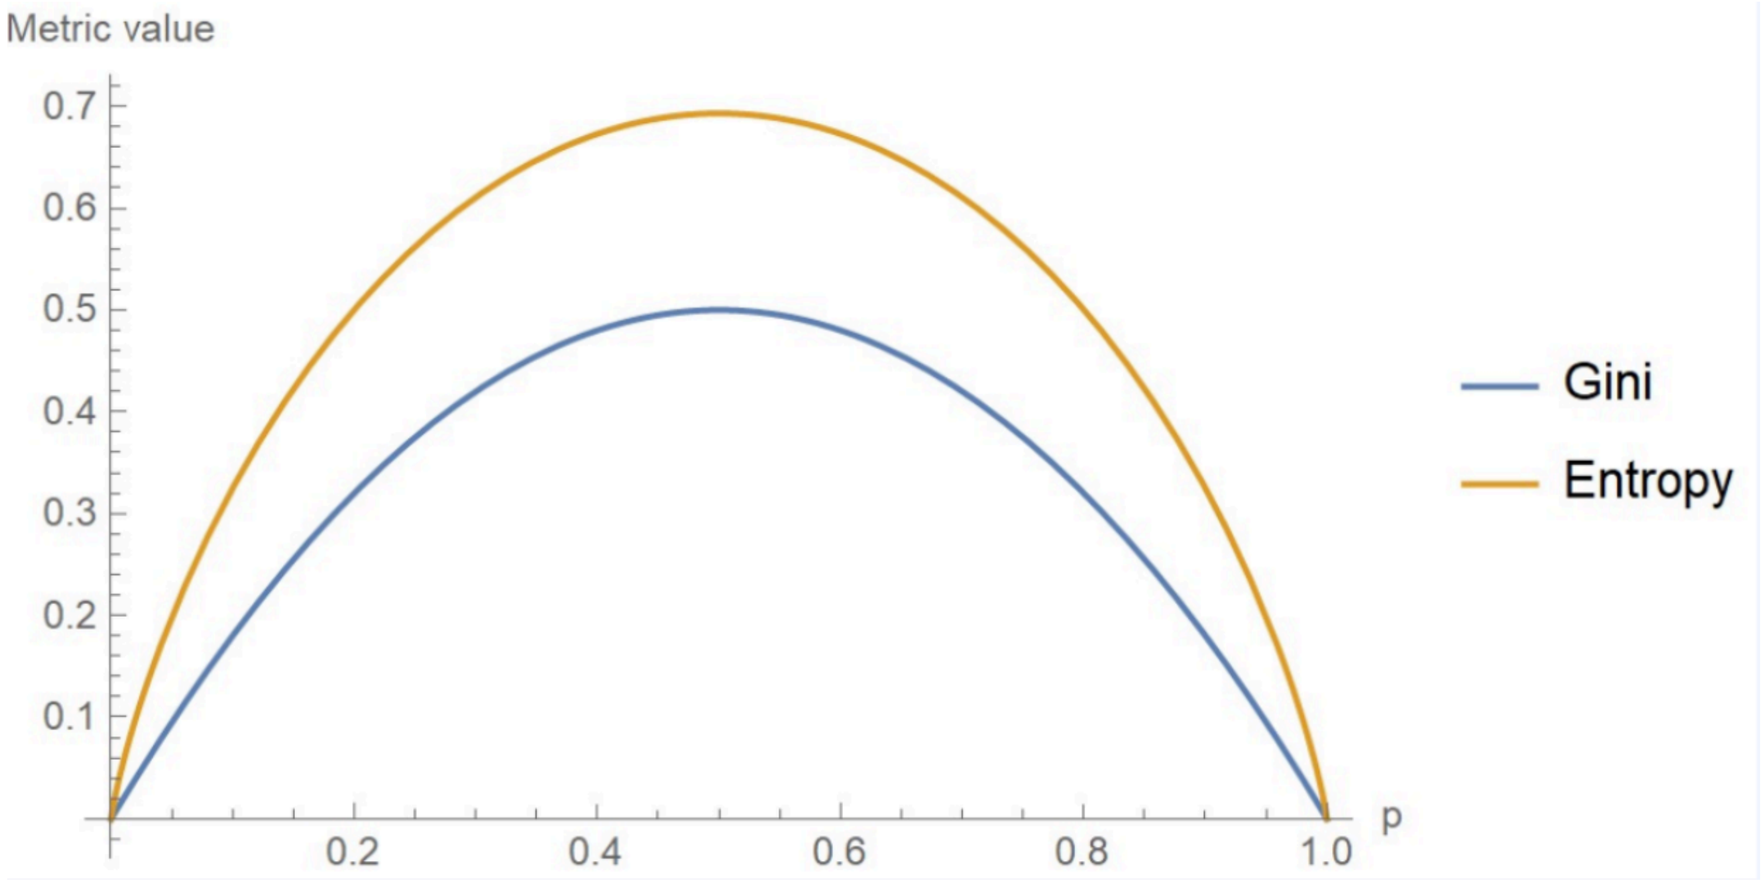
$$I(A) = 1 - \sum_{k=1}^{m} p_k^2$$
$$= 1 - \left(\frac{6}{16}\right)^2 - \left(\frac{10}{16}\right)^2$$
$$\approx 0.47$$

$$\mathrm{E}(A) = -\sum_{k=1}^{m} p_k \log_2\left(p_k\right)$$
$$= -\frac{6}{16}\log_2\left(\frac{6}{16}\right) - \frac{10}{16}\log_2\left(\frac{10}{16}\right)$$
$$\approx 0.95$$

https://wooono.tistory.com/104

그래서 불순도는 뭐죠?

당신의 목적에 맞다면 그게 gini 든 entropy든 상관 없다 (더 좋은 방법이 나올 수도 있다!)



테니스 경기 참가여부 예제

날짜	날씨	온도	습도	바람	참가여부
D1	맑음	더움	높음	약함	X
D2	맑음	더움	높음	강함	X
D3	흐림	더움	높음	약함	O
D4	비	포근	높음	약함	O
D5	비	서늘	정상	약함	O
D6	비	서늘	정상	강함	X
D7	흐림	서늘	정상	강함	O
D8	맑음	포근	높음	약함	X
D9	맑음	서늘	정상	약함	O
D10	비	포근	정상	약함	O
D11	맑음	포근	정상	강함	O
D12	흐림	포근	높음	강함	O
D13	흐림	더움	정상	약함	O
D14	비	포근	높음	강함	X

https://wooono.tistory.com/104

엔트로피(참가여부)

$$= -\frac{9}{14}log_2(\frac{9}{14}) - \frac{5}{14}log_2(\frac{5}{14}) = 0.940$$

총 *14* 경기중 *9*경기는 *O*, *5* 경기는 *X*

모든 데이터가 범주형임

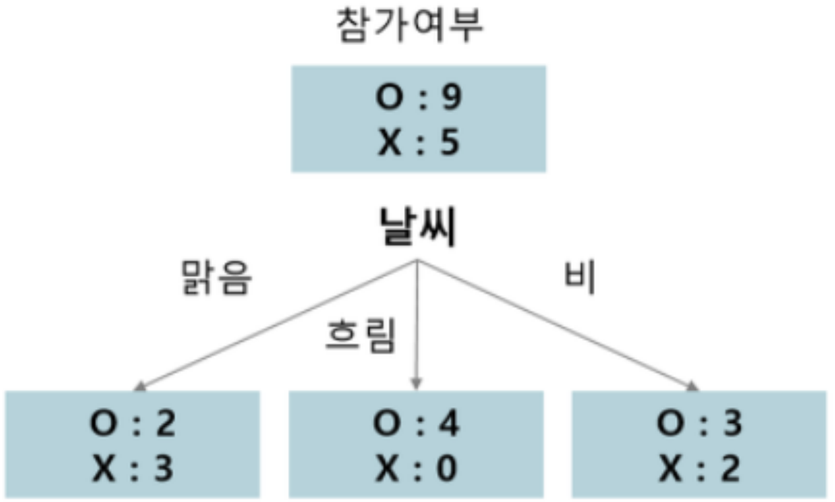
테니스 경기 참가여부 예제

날짜	날씨	온도	습도	바람	참가여부
D1	맑음	더움	높음	약함	X
D2	맑음	더움	높음	강함	X
D3	흐림	더움	높음	약함	O
D4	비	포근	높음	약함	O
D5	비	서늘	정상	약함	O
D6	비	서늘	정상	강함	X
D7	흐림	서늘	정상	강함	O
D8	맑음	포근	높음	약함	X
D9	맑음	서늘	정상	약함	O
D10	비	포근	정상	약함	O
D11	맑음	포근	정상	강함	O
D12	흐림	포근	높음	강함	O
D13	흐림	더움	정상	약함	O
D14	비	포근	높음	강함	X

엔트로피 (참가|날씨)

$$= \frac{5}{14}\left(-\frac{2}{5}log_2\left(\frac{2}{5}\right)-\frac{3}{5}log_2\left(\frac{3}{5}\right)\right)$$
$$+\frac{4}{14}\left(-\frac{4}{4}log_2\left(\frac{4}{4}\right)-\frac{0}{4}log_2\left(\frac{0}{4}\right)\right)$$
$$+\frac{5}{14}\left(-\frac{3}{5}log_2\left(\frac{3}{5}\right)-\frac{2}{5}log_2\left(\frac{2}{5}\right)\right)$$
$$= 0.694$$

***14*경기중 *5*경기가 맑으며, 그 중에 *2*경기를 O...**



테니스 경기 참가여부 예제

날짜	날씨	온도	습도	바람	참가여부
D1	맑음	더움	높음	약함	X
D2	맑음	더움	높음	강함	X
D3	흐림	더움	높음	약함	O
D4	비	포근	높음	약함	O
D5	비	서늘	정상	약함	O
D6	비	서늘	정상	강함	X
D7	흐림	서늘	정상	강함	O
D8	맑음	포근	높음	약함	X
D9	맑음	서늘	정상	약함	O
D10	비	포근	정상	약함	O
D11	맑음	포근	정상	강함	O
D12	흐림	포근	높음	강함	O
D13	흐림	더움	정상	약함	O
D14	비	포근	높음	강함	X

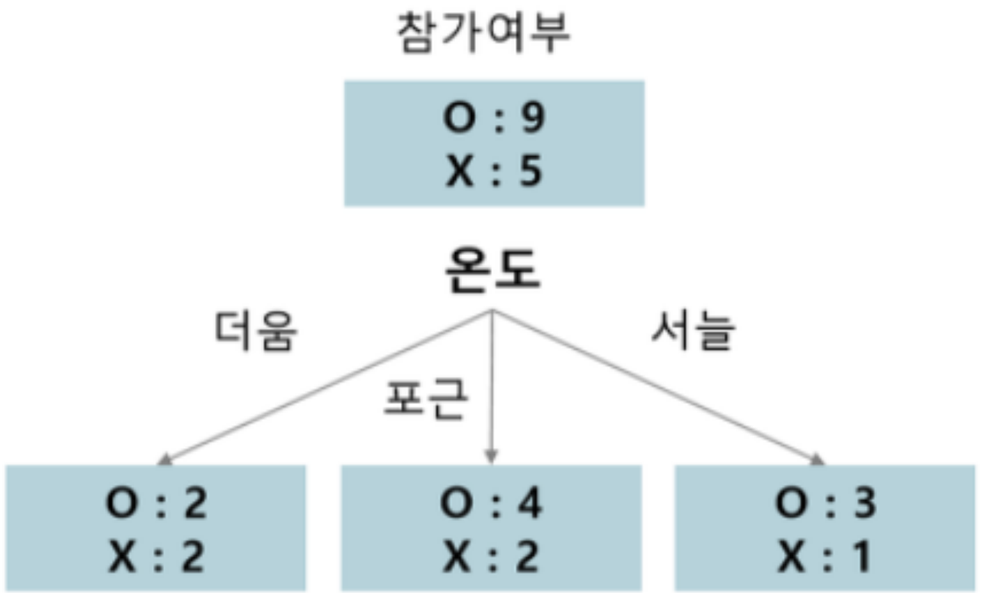
엔트로피 (참가|온도)

$$= \frac{4}{14}\left(-\frac{2}{4}log_2\left(\frac{2}{4}\right)-\frac{2}{4}log_2\left(\frac{2}{4}\right)\right)$$

$$+\frac{6}{14}\left(-\frac{4}{6}log_2\left(\frac{4}{6}\right)-\frac{2}{6}log_2\left(\frac{2}{6}\right)\right)$$

$$+\frac{4}{14}\left(-\frac{3}{4}log_2\left(\frac{3}{4}\right)-\frac{1}{4}log_2\left(\frac{1}{4}\right)\right)$$

$$= 0.911$$



테니스 경기 참가여부 예제

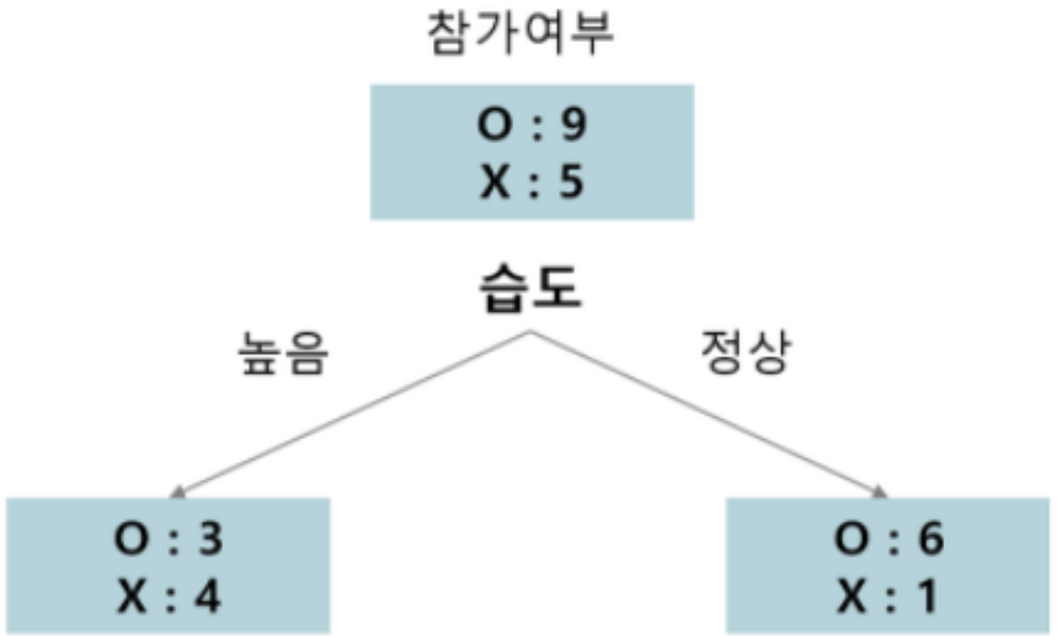
날짜	날씨	온도	습도	바람	참가여부
D1	맑음	더움	높음	약함	X
D2	맑음	더움	높음	강함	X
D3	흐림	더움	높음	약함	O
D4	비	포근	높음	약함	O
D5	비	서늘	정상	약함	O
D6	비	서늘	정상	강함	X
D7	흐림	서늘	정상	강함	O
D8	맑음	포근	높음	약함	X
D9	맑음	서늘	정상	약함	O
D10	비	포근	정상	약함	O
D11	맑음	포근	정상	강함	O
D12	흐림	포근	높음	강함	O
D13	흐림	더움	정상	약함	O
D14	비	포근	높음	강함	X

엔트로피 (참가|습도)

$$= \frac{7}{14}\left(-\frac{3}{7}log_2\left(\frac{3}{7}\right)-\frac{4}{7}log_2\left(\frac{4}{7}\right)\right)$$

$$+\frac{7}{14}\left(-\frac{6}{7}log_2\left(\frac{6}{7}\right)-\frac{1}{7}log_2\left(\frac{1}{7}\right)\right)$$

$$= 0.789$$



테니스 경기 참가여부 예제

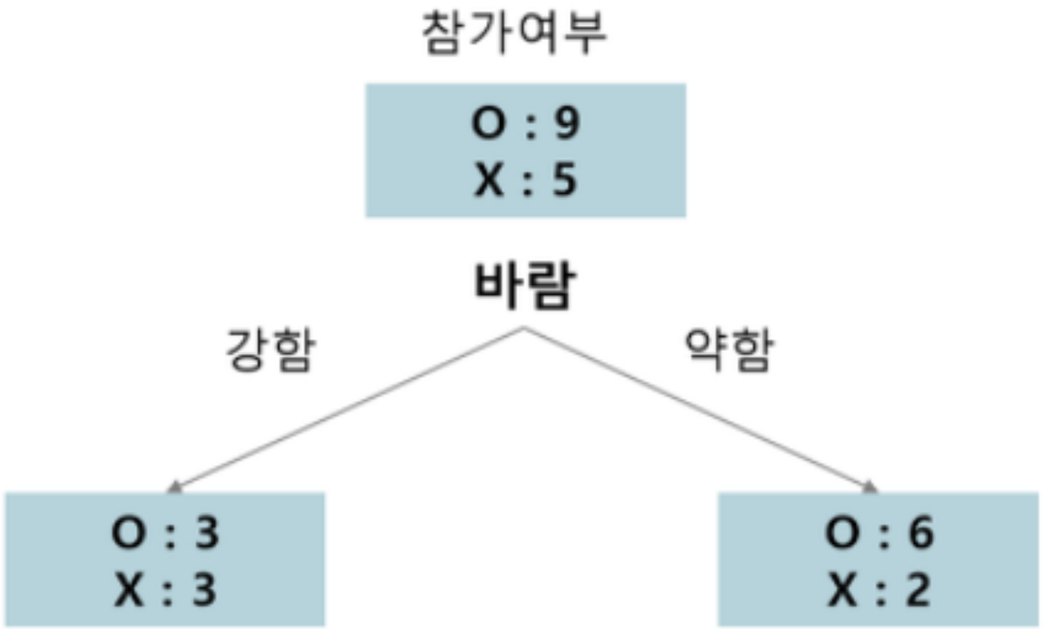
날짜	날씨	온도	습도	바람	참가여부
D1	맑음	더움	높음	약함	X
D2	맑음	더움	높음	강함	X
D3	흐림	더움	높음	약함	O
D4	비	포근	높음	약함	O
D5	비	서늘	정상	약함	O
D6	비	서늘	정상	강함	X
D7	흐림	서늘	정상	강함	O
D8	맑음	포근	높음	약함	X
D9	맑음	서늘	정상	약함	O
D10	비	포근	정상	약함	O
D11	맑음	포근	정상	강함	O
D12	흐림	포근	높음	강함	O
D13	흐림	더움	정상	약함	O
D14	비	포근	높음	강함	X

엔트로피 (참가|바람)

$$= \frac{6}{14}\left(-\frac{3}{6}log_2\left(\frac{3}{6}\right)-\frac{3}{6}log_2\left(\frac{3}{6}\right)\right)$$

$$+\frac{8}{14}\left(-\frac{6}{8}log_2\left(\frac{6}{8}\right)-\frac{2}{8}log_2\left(\frac{2}{8}\right)\right)$$

$$= 0.892$$



INFORMATION GAIN

불순도의 차이 = 이전 불순도 - 이후 불순도
차이의 의미는?

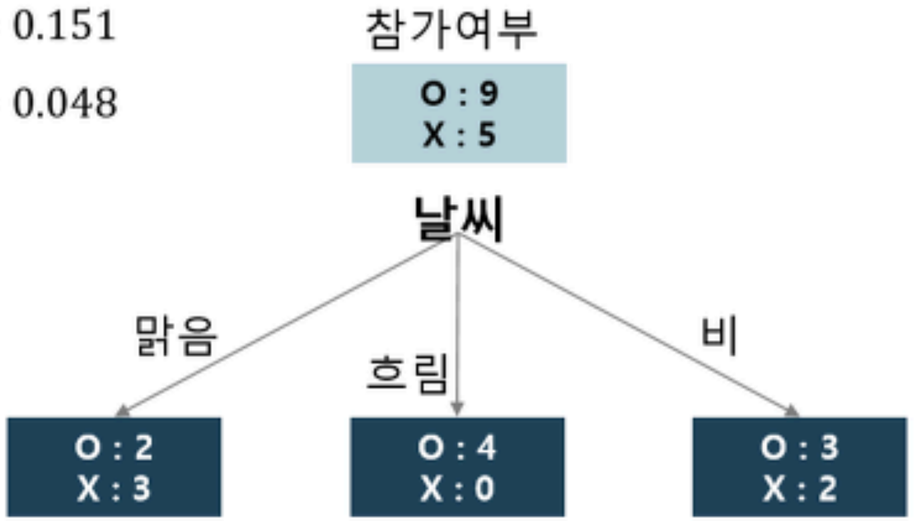
$$IG(\text{경기}, \text{날씨}) = E(\text{경기}) - E(\text{경기}|\text{날씨}) = 0.94 - 0.694 = \mathbf{0.246}$$ → 날씨로 가장 먼저 분류

$$IG(\text{경기}, \text{온도}) = E(\text{경기}) - E(\text{경기}|\text{온도}) = 0.94 - 0.911 = 0.029$$

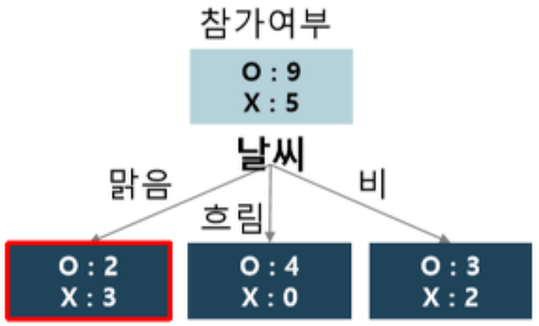
$$IG(\text{경기}, \text{습도}) = E(\text{경기}) - E(\text{경기}|\text{습도}) = 0.94 - 0.789 = 0.151$$

$$IG(\text{경기}, \text{바람}) = E(\text{경기}) - E(\text{경기}|\text{바람}) = 0.94 - 0.892 = 0.048$$

날씨에 의해 얻어지는
"정보 획득량"이 제일 많다!



가장 먼저 나누자



날짜	날씨	온도	습도	바람	참가여부
D1	맑음	더움	높음	약함	X
D2	맑음	더움	높음	강함	X
D8	맑음	포근	높음	약함	X
D9	맑음	서늘	정상	약함	O
D11	맑음	포근	정상	강함	O

(Approach 1)

$$E(\text{경기}) = -\frac{2}{5}log_2\left(\frac{2}{5}\right) - \frac{3}{5}log_2\left(\frac{3}{5}\right) = 0.971$$

(Approach 2)

$$E(\text{경기}|\text{온도}) = \frac{2}{5}\left(-\frac{2}{2}log_2\left(\frac{2}{2}\right)\right) + \frac{2}{5}\left(-\frac{1}{2}log_2\left(\frac{1}{2}\right) - \frac{1}{2}log_2\left(\frac{1}{2}\right)\right) + \frac{1}{5}\left(-\frac{1}{1}log_2\left(\frac{1}{1}\right)\right) = 0.4$$

$$E(\text{경기}|\text{습도}) = \frac{3}{5}\left(-\frac{3}{3}log_2\left(\frac{3}{3}\right)\right) + \frac{2}{5}\left(-\frac{2}{2}log_2\left(\frac{2}{2}\right)\right) = 0$$

$$E(\text{경기}|\text{바람}) = \frac{2}{5}\left(-\frac{1}{2}log_2\left(\frac{1}{2}\right) - \frac{1}{2}log_2\left(\frac{1}{2}\right)\right) + \frac{3}{5}\left(-\frac{1}{3}log_2\left(\frac{1}{3}\right) - \frac{2}{3}log_2\left(\frac{2}{3}\right)\right) = 0.951$$

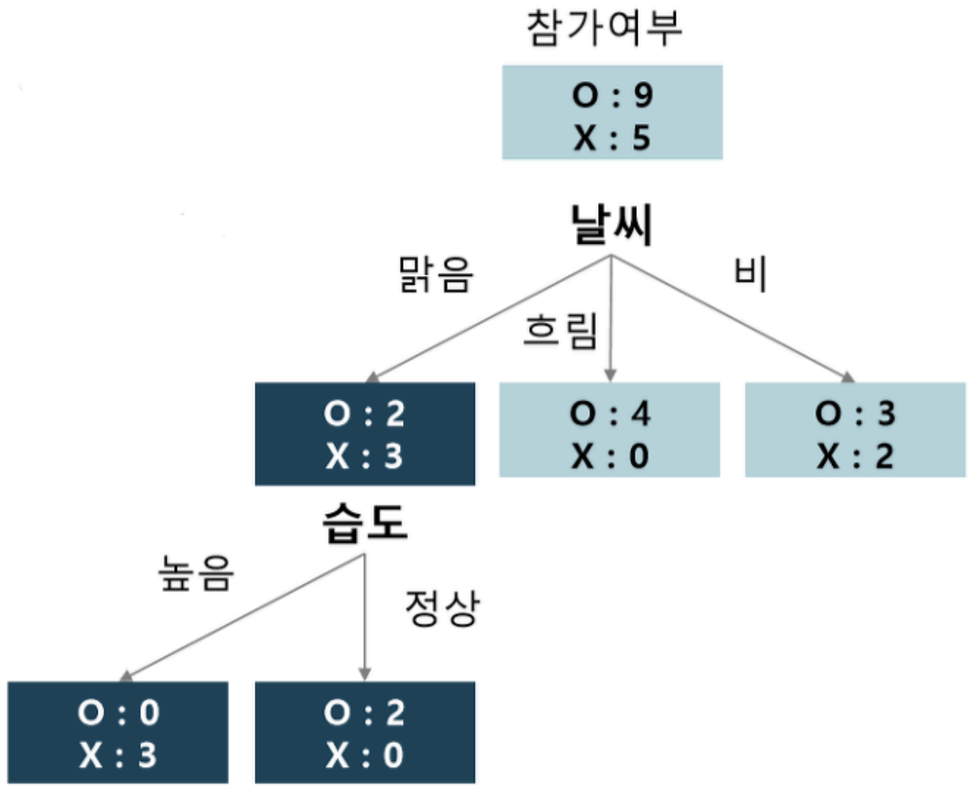
(Approach 3)

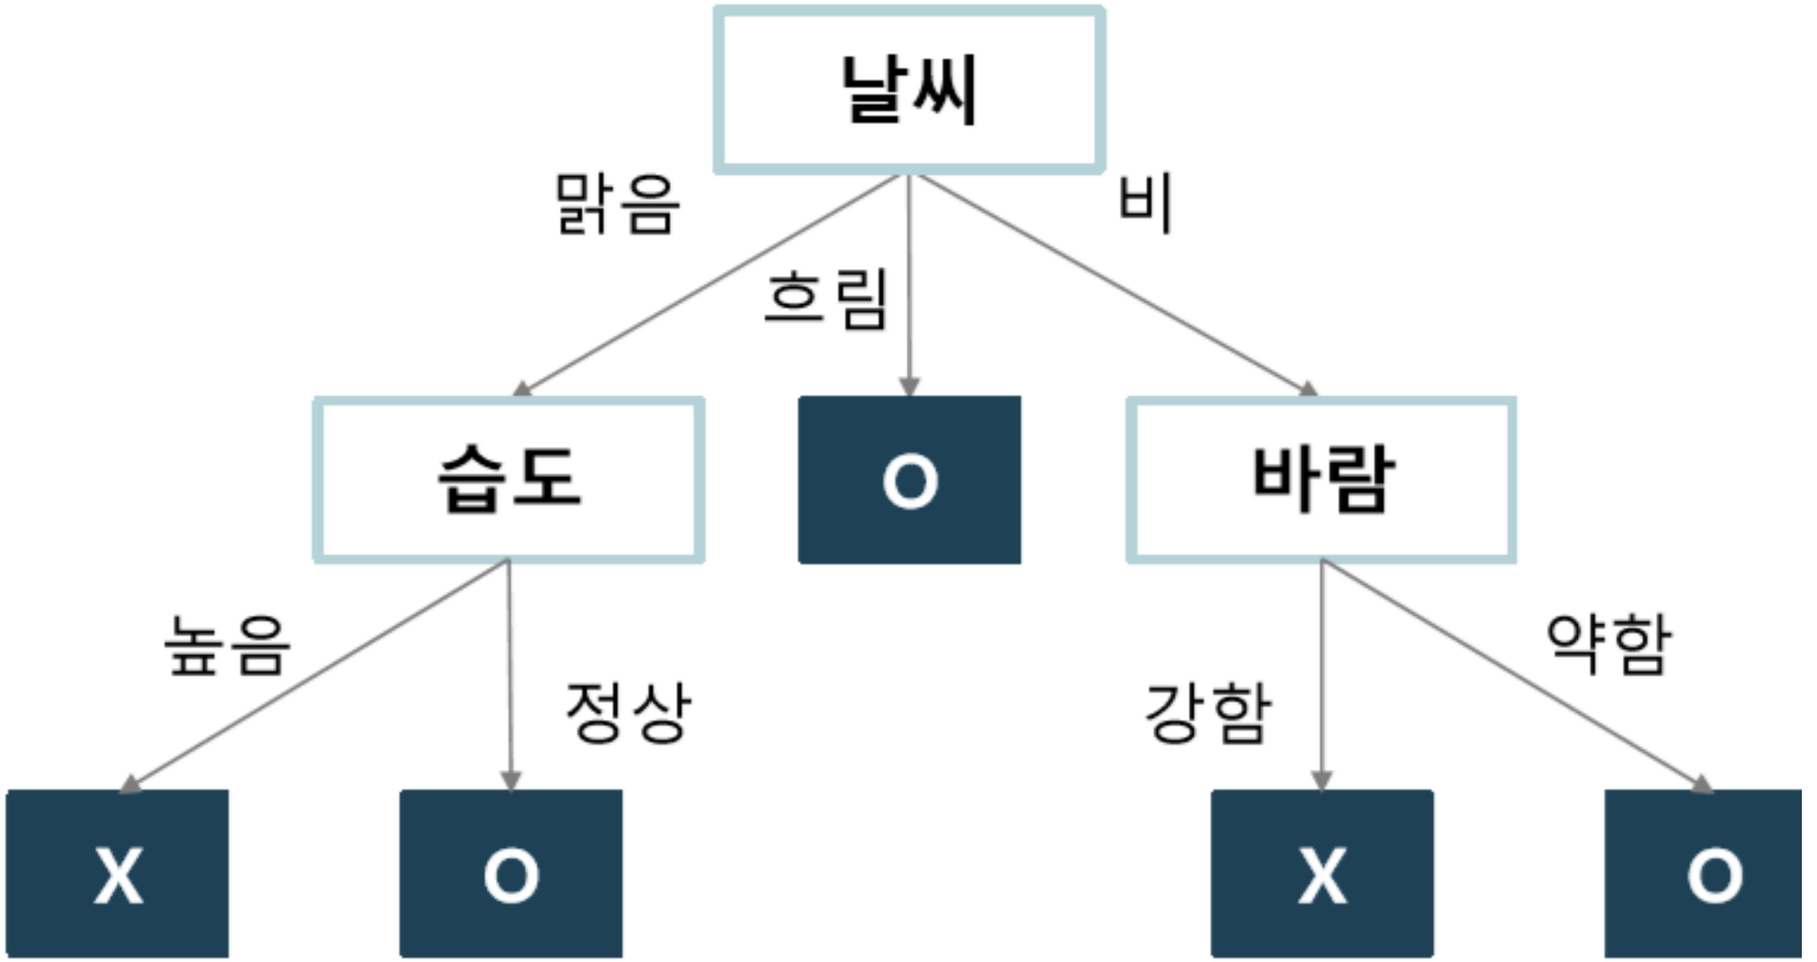
$$IG(\text{경기}, \text{온도}) = E(\text{경기}) - E(\text{경기}|\text{온도}) = 0.971 - 0.4 = 0.571$$

$$IG(\text{경기}, \text{습도}) = E(\text{경기}) - E(\text{경기}|\text{습도}) = 0.971 - 0 = \mathbf{0.971}$$

$$IG(\text{경기}, \text{바람}) = E(\text{경기}) - E(\text{경기}|\text{바람}) = 0.971 - 0.951 = 0.02$$

이후 모든 노드의 *IG*가 *0*이 될때까지 반복




날씨
맑음
흐림
비
습도
O
바람
높음
정상
강함
약함
X
O
X
O

수치형 변수인 경우

수입, 주택크기, 구입여부

Income	Lot size	Ownership
60.0	18.4	Owner
85.5	16.8	Owner
64.8	21.6	Owner
61.5	20.8	Owner
87.0	23.6	Owner
110.1	19.2	Owner
108.0	17.6	Owner
82.8	22.4	Owner
69.0	20.0	Owner
93.0	20.8	Owner
51.0	22.0	Owner
81.0	20.0	Owner
75.0	19.6	Non-owner
52.8	20.8	Non-owner
64.8	17.2	Non-owner
43.2	20.4	Non-owner
84.0	17.6	Non-owner
49.2	17.6	Non-owner
59.4	16.0	Non-owner
66.0	18.4	Non-owner
47.4	16.4	Non-owner
33.0	18.8	Non-owner
51.0	14.0	Non-owner
63.0	14.8	Non-owner

*24*개 경우

LOT 기준 정렬

Income	Lot size	Ownership
51.0	14.0	Non-owner
63.0	14.8	Non-owner
59.4	16.0	Non-owner
47.4	16.4	Non-owner
85.5	16.8	Owner
64.8	17.2	Non-owner
108.0	17.6	Owner
84.0	17.6	Non-owner
49.2	17.6	Non-owner
60.0	18.4	Owner
66.0	18.4	Non-owner
33.0	18.8	Non-owner
110.1	19.2	Owner
75.0	19.6	Non-owner
69.0	20.0	Owner
81.0	20.0	Owner
43.2	20.4	Non-owner
61.5	20.8	Owner
93.0	20.8	Owner
52.8	20.8	Non-owner
64.8	21.6	Owner
51.0	22.0	Owner
82.8	22.4	Owner
87.0	23.6	Owner

분기 전 엔트로피 $= -\frac{1}{2}\log_2(\frac{1}{2}) - \frac{1}{2}\log_2(\frac{1}{2}) = 1$

분기 후 엔트로피 $= \frac{1}{24}(-\log_2 1) + \frac{23}{24}\left(-\frac{12}{23}\log_2(\frac{12}{23}) - \frac{11}{23}\log_2(\frac{11}{23})\right) \approx 0.96$

정보획득 $= 1 - 0.96 = 0.04$

모든 변수 별, 모든 개체 별 *IG* 계산 실시..

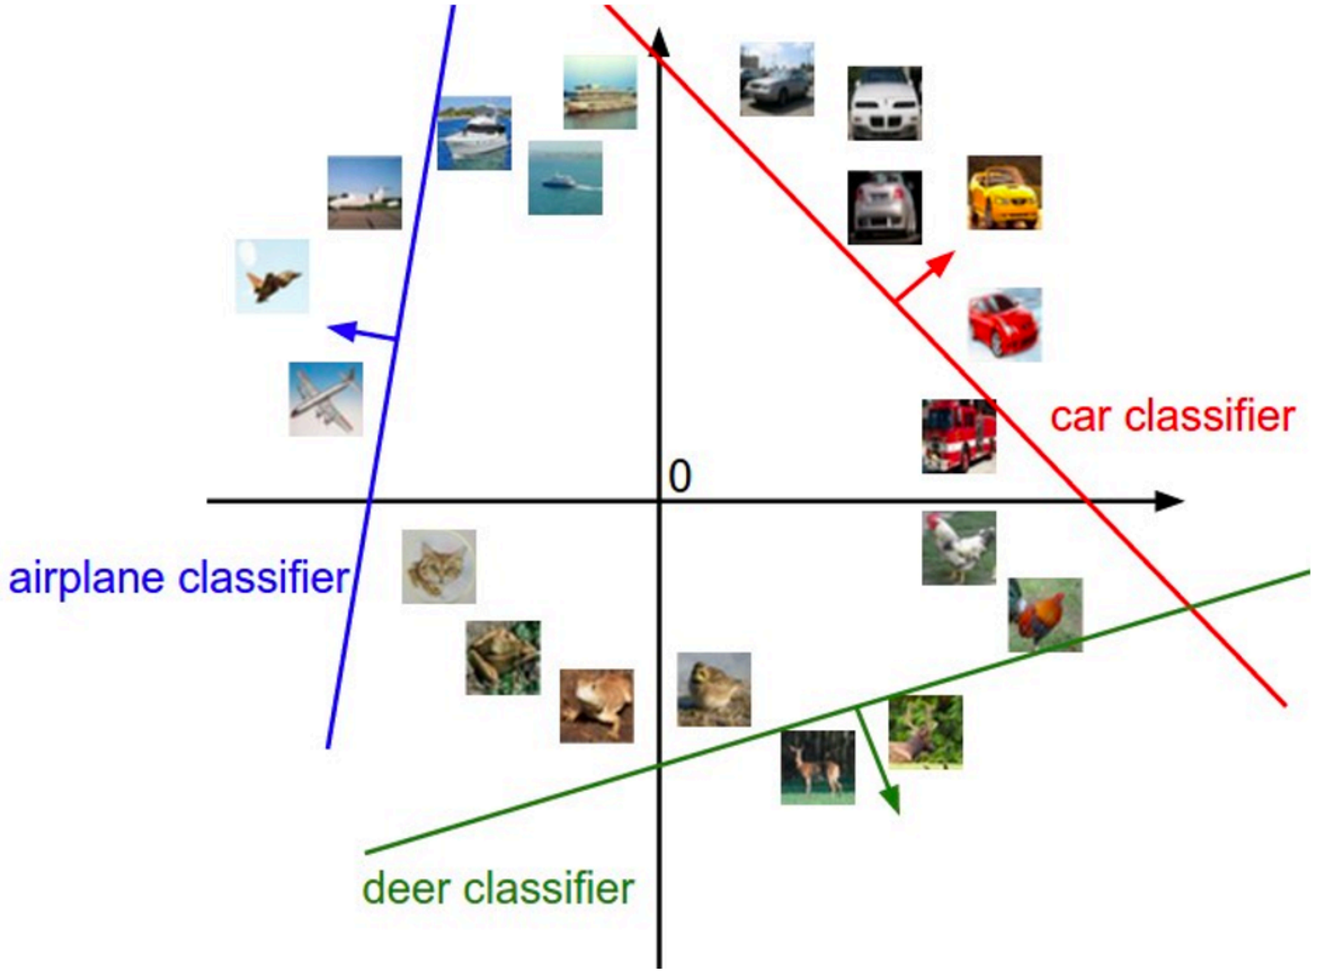
변수 *2*개, 총 개체 *24*개

2(24-1) = 46*

그 중 최고를 선택하여 분기를 생성

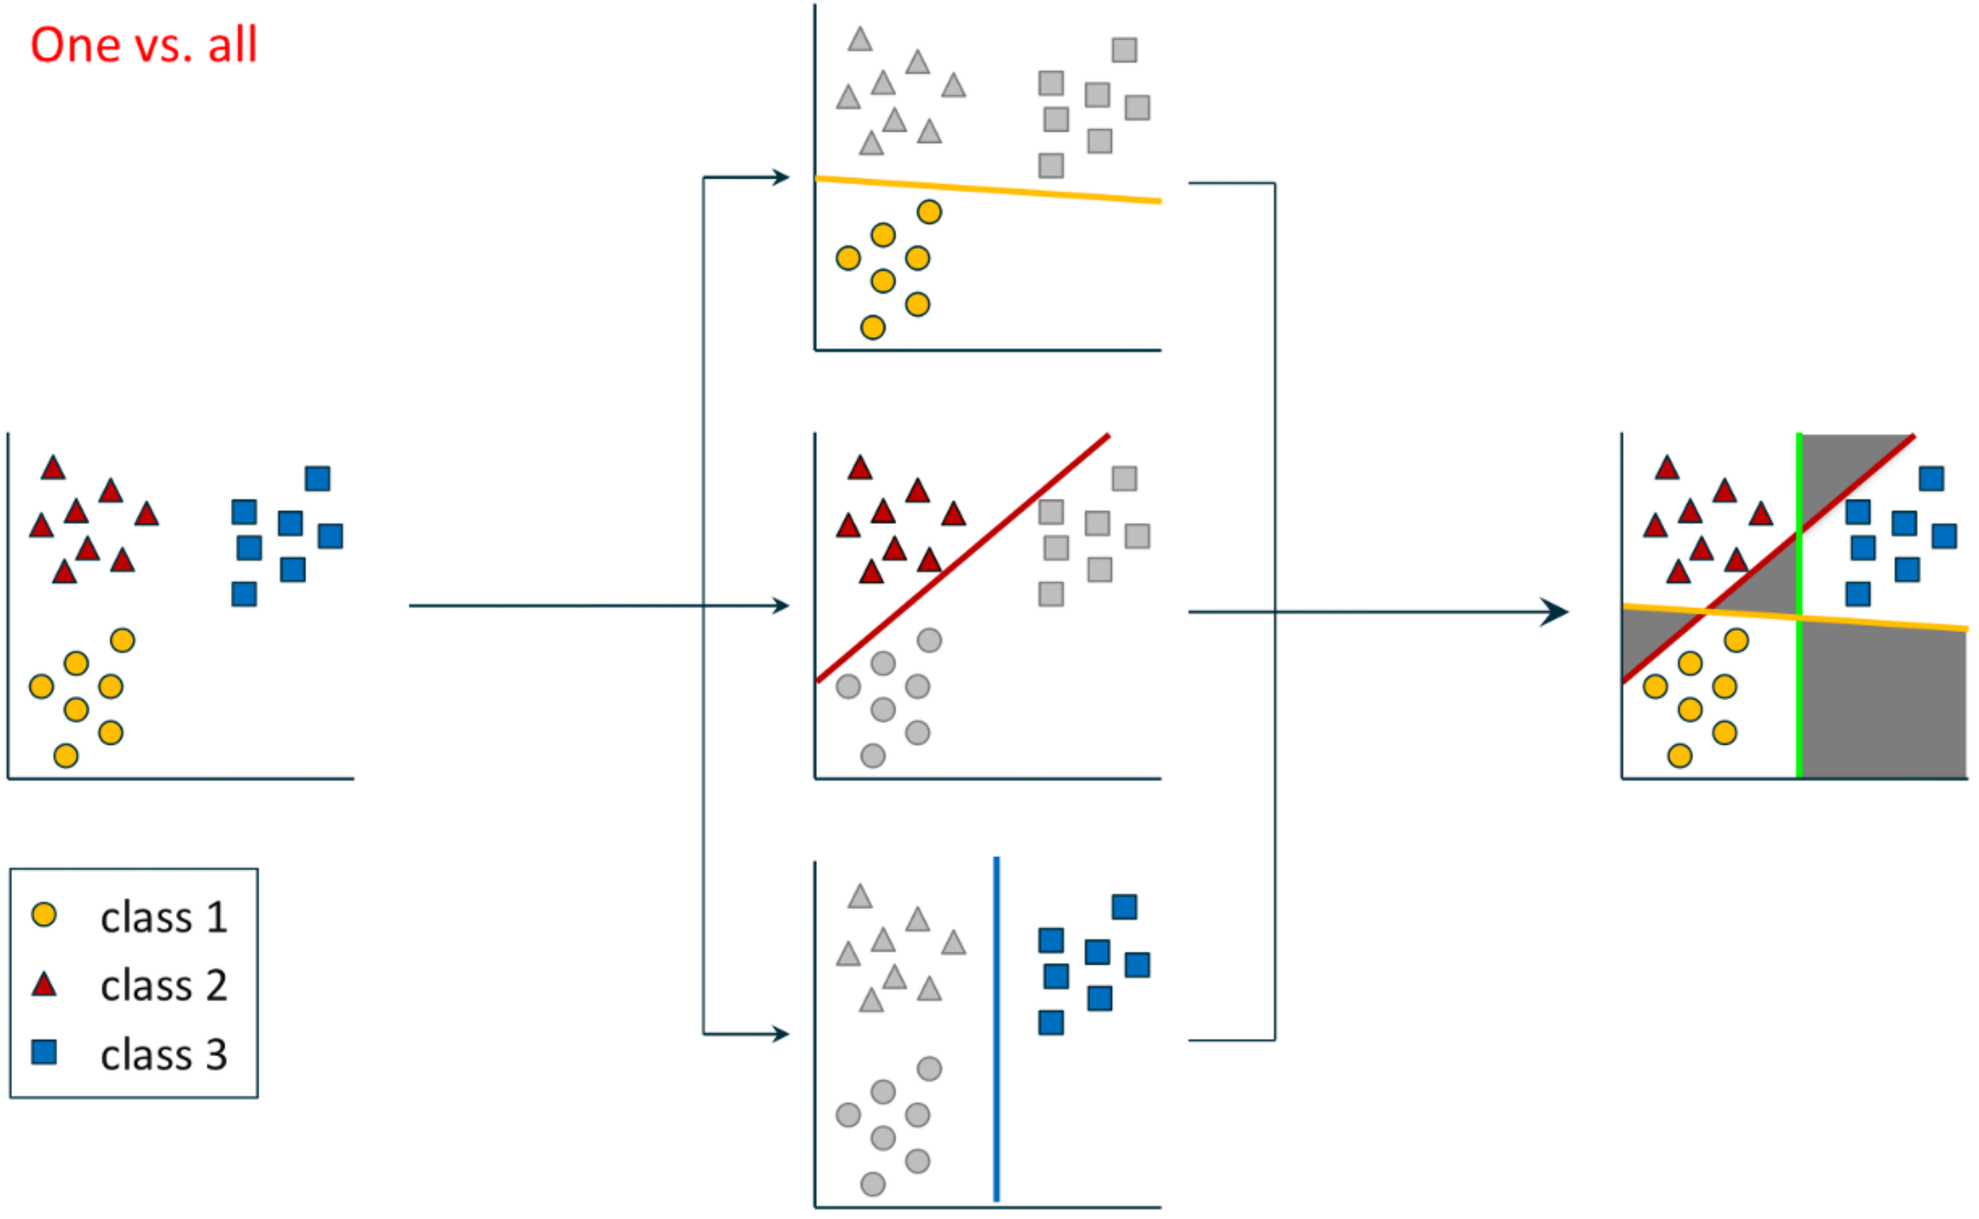
이를 *IG*가 *0*이될때까지 반복

Multiclass classification

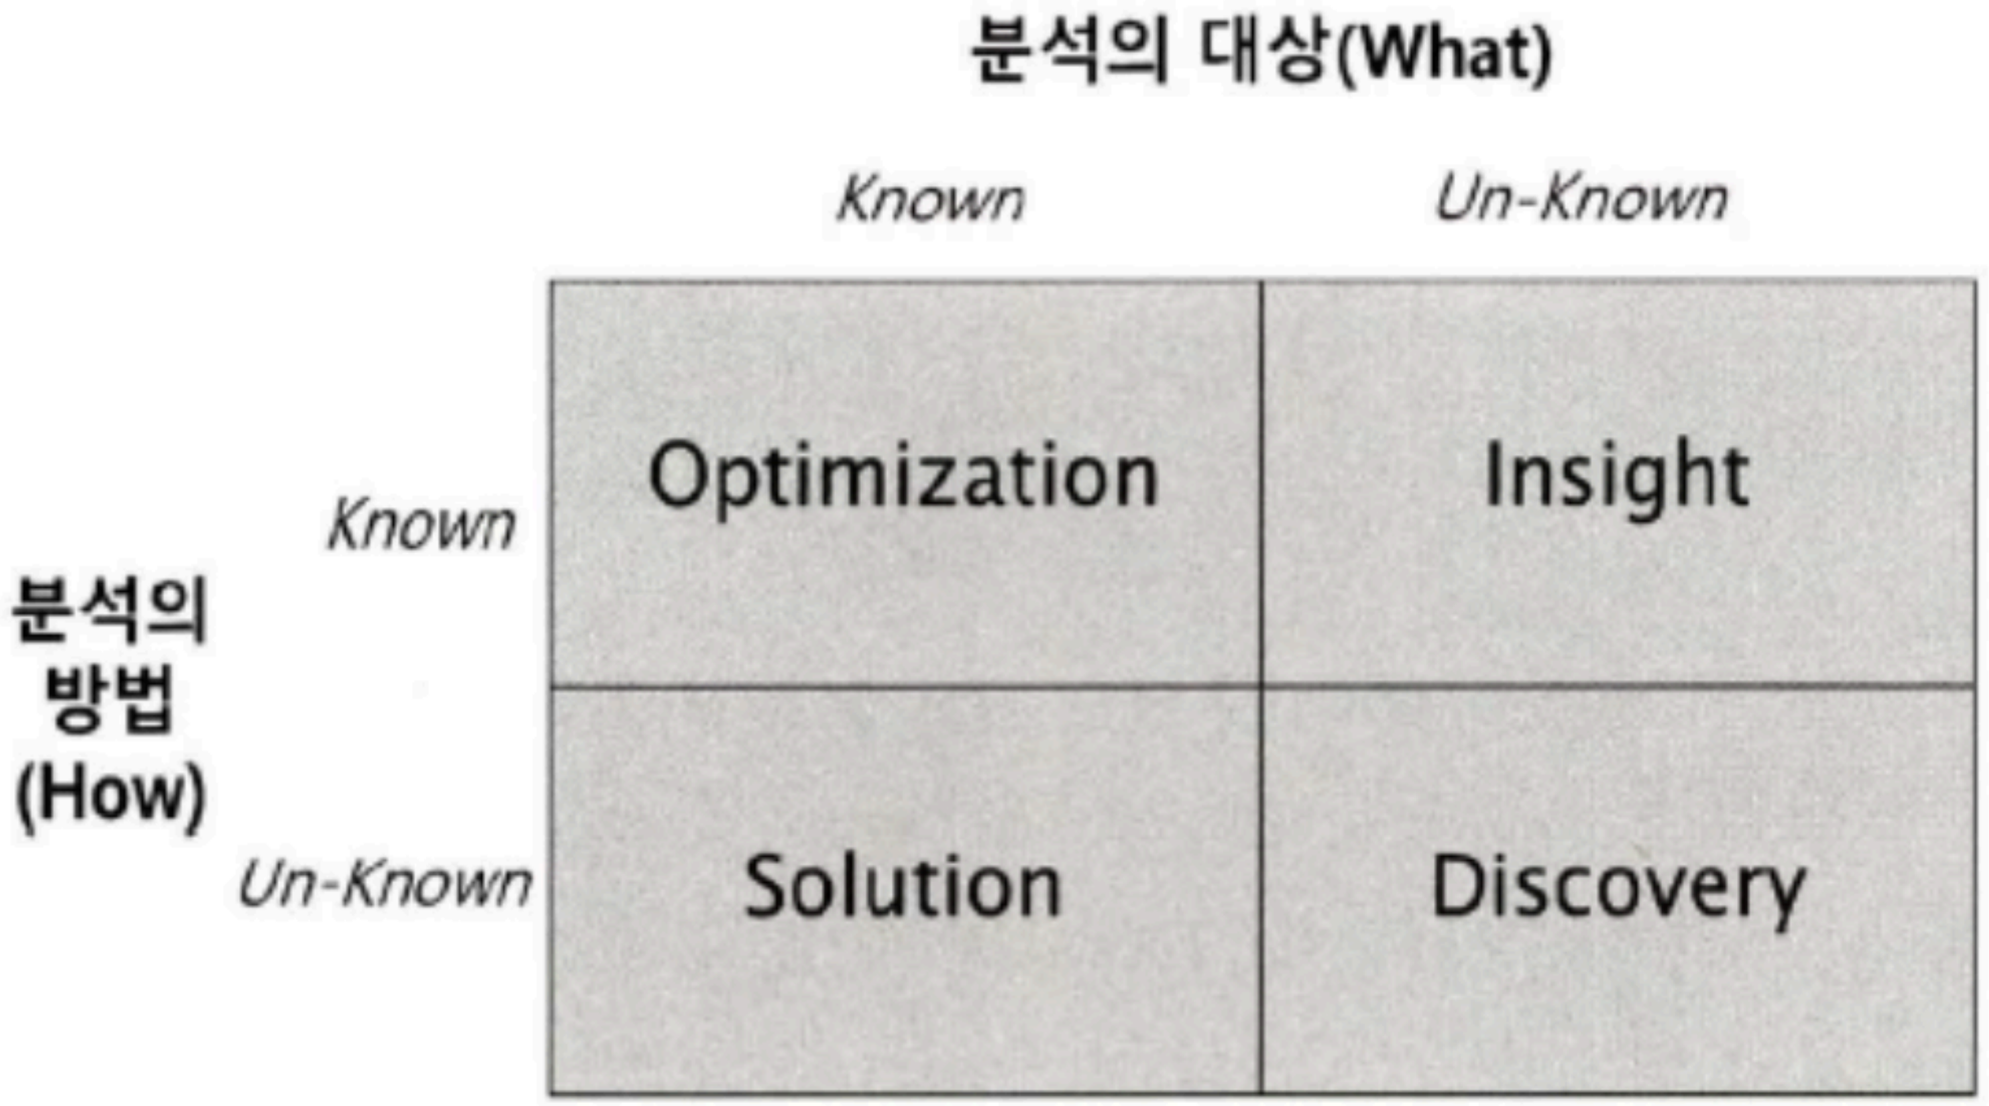


Class가 여러개인 경우 어떻게 될까?

One vs. all



데이터 중요한가요?!


분석의 대상(What)
Known
Un-Known
분석의 방법 (How)
Known
Un-Known
Optimization
Insight
Solution
Discovery