체인룰과 오차역전파

미분을 곱해서 연결하고, 오차를 뒤로 전달하기

오늘 배울 내용

01

체인룰

미분을 곱해서 연결하기, 시그모이드 미분

02

날씨 예제: dw 구하기

손실 함수 종류, 체인룰로 dw 구하고 경사하강법으로 업데이트

03

학습의 3단계

순전파 → 손실 계산 → 역전파

04

역전파 설명

층이 여러 개일 때 오차를 뒤로 전달하는 방법

05

역전파 예시

은닉층이 있는 신경망에서 w 6개의 기울기 구하기

06

실습과 문제

빈칸 채우기 코드, 직접 풀어 보는 문제 2개

01 체인룰 (연쇄 법칙)

합성함수의 미분 = 각 단계 미분의 곱

체인룰: 바깥 미분 × 안쪽 미분

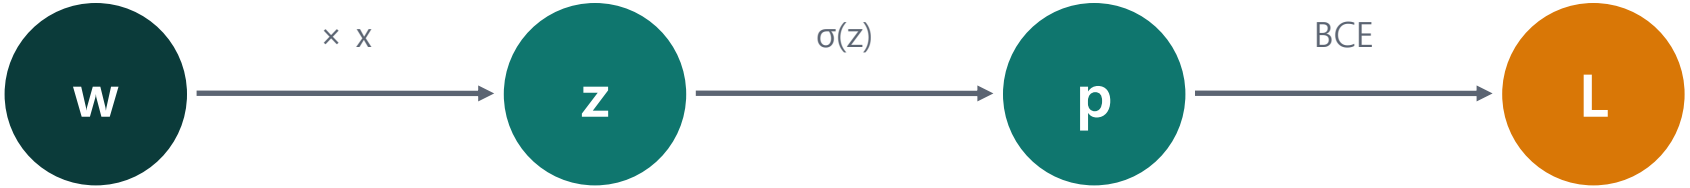
$$y = f(u),\ u = g(x) \text{ 일 때 } \frac{dy}{dx} = \frac{dy}{du} \times \frac{du}{dx}$$

예시: $(ax - b)^2$을 x로 미분하기

안쪽을 u로	바깥 미분	안쪽 미분	곱하기
$u = ax - b,\ y = u^2$	$\frac{dy}{du} = 2u = 2(ax - b)$	$\frac{du}{dx} = a$	$2a(ax - b)$

단계가 몇 개든 각 단계의 미분을 차례로 곱하면 돼요.

한 줄로 이어진 계산은 국소 미분을 곱한다



$\partial z/\partial w = x$

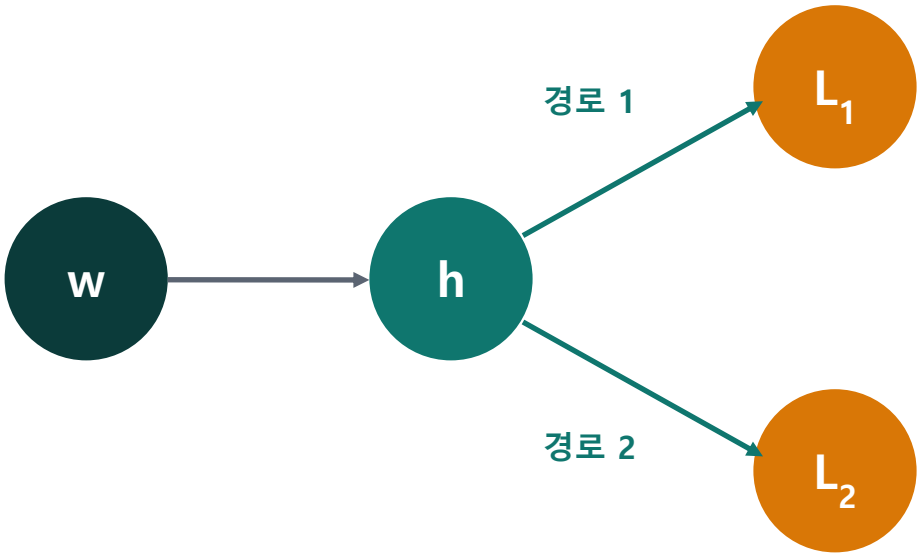
$\partial p/\partial z = p(1 - p)$

$\partial L/\partial p$

σ(z): 시그모이드 함수, BCE: 이진 분류용 손실 함수 (02에서 자세히) · 미분은 L에서 w 쪽으로 곱해 나가요

$$\partial L/\partial w = \partial L/\partial p \times \partial p/\partial z \times \partial z/\partial w$$

경로가 여러 개면 더한다



$L = L_1 + L_2$ 이므로

$$\frac{\partial L}{\partial w} = \frac{\partial L_1}{\partial h} \times \frac{\partial h}{\partial w} + \frac{\partial L_2}{\partial h} \times \frac{\partial h}{\partial w}$$

w를 바꾸면 h가 바뀌고, h는 L_1과 L_2를 둘 다 바꿔요. 그래서 두 경로의 영향을 모두 더해야 해요.

체인룰 적용: 시그모이드 미분하기

$$\sigma(z) = (1 + e^{-z})^{-1}$$

$$\sigma'(z) = -(1 + e^{-z})^{-2} \times (-e^{-z})$$

$$= e^{-z} / (1 + e^{-z})^2$$

$$= 1/(1 + e^{-z}) \times e^{-z}/(1 + e^{-z})$$

$$= \sigma(z) \times (1 - \sigma(z))$$

바깥 미분

$u^{-1} \rightarrow -u^{-2}$

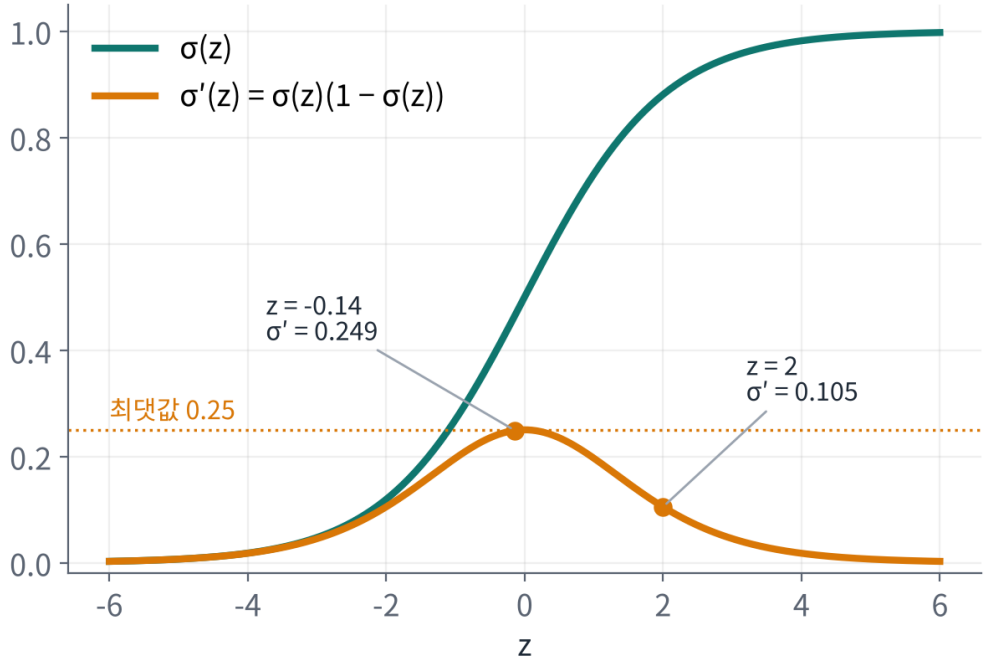
안쪽 미분

$1 + e^{-z} \rightarrow -e^{-z}$

마지막 줄 비결

$e^{-z}/(1 + e^{-z}) = 1 - \sigma(z)$

시그모이드 미분의 성질



z	σ(z)	σ′(z) = σ(1 − σ)
0	0.500	**0.250**
−0.14	0.465	**0.249**
2	0.881	**0.105**

- σ 값만 알면 미분값도 바로 계산돼요
- 최댓값은 0.25 (z = 0일 때)
- z가 0에서 멀수록 0에 가까워져요

02

날씨 예제: dw 구하기

손실 함수를 고르고, 체인룰로 미분하고, 경사하강법으로 업데이트

손실 함수란? 대표적인 종류

손실 함수	식 (데이터 1개)	특징	주로 쓰는 곳
MSE	$(\hat{y} - y)^2$	크게 틀릴수록 제곱으로 크게 벌점	회귀
MAE	$\lvert\hat{y} - y\rvert$	이상치(튀는 값)에 덜 민감	회귀
Huber	작으면 제곱, 크면 절댓값	MSE와 MAE의 중간	회귀 (이상치 있을 때)
BCE	$-[y \cdot \log p + (1-y) \cdot \log(1-p)]$	확률을 맞히는 문제, 확신하고 틀리면 큰 벌점	**이진 분류**
크로스엔트로피	$-\log$(정답 클래스의 확률)	BCE를 클래스 여러 개로 확장	다중 분류

날씨 예제는 "비 / 맑음" 두 가지로 나누는 이진 분류라서 BCE를 써요.

문제 유형별 대표 조합

회귀

집값, 기온, 연봉 예측

출력층 활성화

없음 (값 그대로)

손실 함수

MSE / MAE

```
nn.MSELoss()
```

이진 분류

비/맑음, 스팸/정상, 악성/양성

출력층 활성화

시그모이드

손실 함수

BCE

```
nn.BCELoss()
nn.BCEWithLogitsLoss()
```

다중 분류

가위·바위·보, 손글씨 숫자 0~9

출력층 활성화

소프트맥스

손실 함수

크로스엔트로피

```
nn.CrossEntropyLoss()
```

분류에서 MSE 대신 BCE를 쓰는 이유

예측 p	상황	MSE 기울기 2(p−y)·p(1−p)	BCE 기울기 p − y	MSE loss	BCE loss
0.465	애매하게 틀림	−0.266	−0.535	0.29	0.77
0.1	많이 틀림	−0.162	−0.900	0.81	2.30
0.01	확신하고 틀림	**−0.020**	**−0.990**	0.98	**4.61**

MSE의 문제

시그모이드 미분 p(1−p)가 곱해져 남아서, 확신하고 틀릴수록 기울기가 0에 가까워져요. 가장 많이 고쳐야 할 때 거의 안 움직여요.

BCE의 장점

p(1−p)가 약분돼서 기울기가 p − y로 틀린 만큼 그대로 나와요. 확신하고 틀리면 loss도 크게 올라가요.

모델과 손실 함수

첫 번째 데이터 (비 오는 날)

$x_1 = 0.8,\ x_2 = 0.6,\ y = 1$
$w_1 = 0.3,\ w_2 = 0.2,\ b = -0.5$

처음 값은 퍼셉트론 예제와 같아요

y = 1이면 L = –log p 만 남아요. p가 1에 가까울수록 0에 가까워져요.

가중합

$$z = w_1x_1 + w_2x_2 + b$$

예측 확률

$$p = \sigma(z) = 1 / (1 + e^{-z})$$

손실 (BCE)

$$L = -[\, y \cdot \log p + (1 - y) \cdot \log(1 - p) \,]$$

예측하고 loss 계산하기

$z = 0.8 \times 0.3 + 0.6 \times 0.2 - 0.5$

−0.14

→

$p = \sigma(-0.14)$

0.465

→

$L = -\log(0.465)$

0.766

해석

- 비 오는 날인데 비 올 확률을 46.5%로만 예측했어요. 그래서 loss가 0.766으로 커요.
- 목표는 p를 1 쪽으로 올려서 loss를 줄이는 것이에요.
- 그러려면 w_1, w_2, b를 각각 어느 쪽으로 얼마나 바꿔야 할지, 즉 dw를 알아야 해요.

체인룰로 미분 조각 세 개 구하기

$$dw_1 = \partial L/\partial w_1 = ① \partial L/\partial p \times ② \partial p/\partial z \times ③ \partial z/\partial w_1$$

① $\partial L/\partial p$

$-y/p + (1-y)/(1-p)$

$= -1 / 0.465 = -2.150$

loss가 p에 얼마나 민감한가

② $\partial p/\partial z$

$p(1 - p)$

$= 0.465 \times 0.535 = 0.249$

01에서 구한 시그모이드 미분

③ $\partial z/\partial w_1$

x_1

$= 0.8$

w_1에 곱해진 입력값

w_2로 미분하면 ③이 $x_2 = 0.6$, b로 미분하면 ③이 1이 돼요. ①, ②는 셋이 똑같이 공유해요.

①×② 를 곱하면 깔끔하게 p − y

$$[\ -y/p + (1-y)/(1-p)\ ] \times p(1-p)$$

$$= -y(1-p) + (1-y)p$$

$$= -y + yp + p - yp$$

$$\mathbf{= p - y}$$

숫자로 확인: −2.150 × 0.249 = −0.535 = 0.465 − 1

$$\mathbf{dw_1 = (p - y) \times x_1}$$

오차 × 입력값

시그모이드와 BCE를 함께 쓰면 분모가 약분돼서 퍼셉트론 학습 규칙과 같은 모양이 돼요. 다른 점은 p가 0/1이 아니라 확률이라는 것뿐이에요.

경사하강법으로 업데이트하기

파라미터	기울기 = (p − y) × 입력	값	새 값 (lr = 0.1)
w_1	−0.535 × 0.8	**−0.428**	0.3 → 0.343
w_2	−0.535 × 0.6	**−0.321**	0.2 → 0.232
b	−0.535 × 1	**−0.535**	−0.5 → −0.447

예측 확률 p

0.465 → 0.492

loss

0.766 → 0.710

데이터 7개 전체로 하면: 평균 기울기

```
p   = [sigmoid(x1*w1 + x2*w2 + b) for x1, x2 in X]
err = [pi - yi for pi, yi in zip(p, Y)]

dw1 = sum(e*x1 for e, (x1, x2) in zip(err, X)) / n
dw2 = sum(e*x2 for e, (x1, x2) in zip(err, X)) / n
db  = sum(err) / n

w1 -= lr * dw1
w2 -= lr * dw2
b  -= lr * db
```

err

p − y. ①×②를 약분한 결과

× x1, × x2

③ 각 w에 곱해진 입력값

sum / n

loss가 7개 평균이라 기울기도 평균

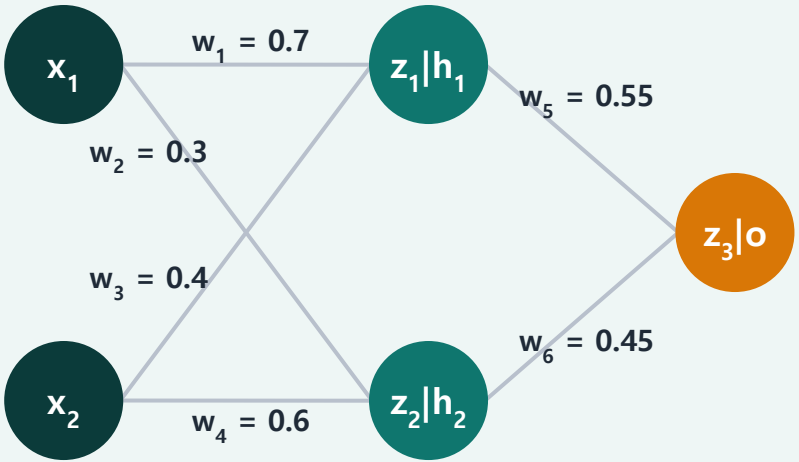
-= lr × dw

기울기 반대로 조금 이동

03 학습의 3단계

순전파 → 손실 계산 → 역전파

학습(training) = 최적화(optimization)



1. **순전파 (feedforward)**
   입력에서 출력까지 차례로 계산

2. **손실 계산**
   예측값과 정답을 비교해 loss 구하기

3. **역전파 (backpropagation)**
   loss에서 거꾸로 가며 모든 w의 기울기 구하기

4. **업데이트**
   w ← w − lr × 기울기 (경사하강법)

날씨 예제를 3단계로 다시 보면

1 순전파

$z = -0.14 \rightarrow p = 0.465$

2 손실 계산

$L = -\log(0.465) = 0.766$

3 기울기 구하기

$dw_1 = (p - y) \times x_1 = -0.428$

4 업데이트

$w_1 = 0.3 \rightarrow 0.343$

날씨 예제는 층이 하나라서 3단계가 체인룰 한 번으로 끝났어요. 층이 여러 개가 되면 3단계에서 오차를 층마다 뒤로 넘겨줘야 하는데, 이 과정을 역전파라고 해요.

04 역전파 설명

층이 여러 개일 때 오차를 뒤로 전달하기

왜 역전파가 필요할까

문제

신경망의 w는 수천~수백만 개예요. w마다 loss까지의 경로를 처음부터 따로 미분하면 같은 계산을 계속 반복하게 돼요.

아이디어

뒤쪽 층에서 계산한 오차를 앞쪽 층이 그대로 받아서 재사용해요. 그러면 모든 w의 기울기를 한 번의 역방향 계산으로 구할 수 있어요.

loss → **출력층** → **은닉층** → **입력 쪽 w**

오차가 출력에서 입력 방향으로 거꾸로 전달되는 것처럼 보여서 "역전파"라고 불러요.

층이 하나일 때 vs 여러 개일 때

층 1개 (날씨 예제)

x → z → p → L

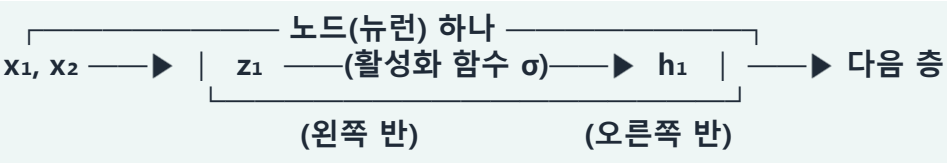
- 모든 w가 출력 바로 앞에 붙어 있어요
- 체인룰 한 번으로 공식이 나와요
- dw = (p − y) × x

층 여러 개 (은닉층 있음)

x → h → o → L

- 입력 쪽 w는 loss까지 가는 길이 길어요
- 출력층 오차 δ_3를 먼저 구하고
- δ_3를 은닉층으로 넘겨 δ_1, δ_2를 만들어요
- 이렇게 오차를 뒤로 넘기는 게 역전파

표기법: z, h, δ





선형 변환 활성화

z : 앞 층 값 × w를 모두 더한 값

$z_1 = x_1 \cdot w_1 + x_2 \cdot w_3$

h : z를 활성화 함수에 넣은 값

$h_1 = \sigma(z_1)$

δ : 그 노드의 z가 loss에 주는 영향

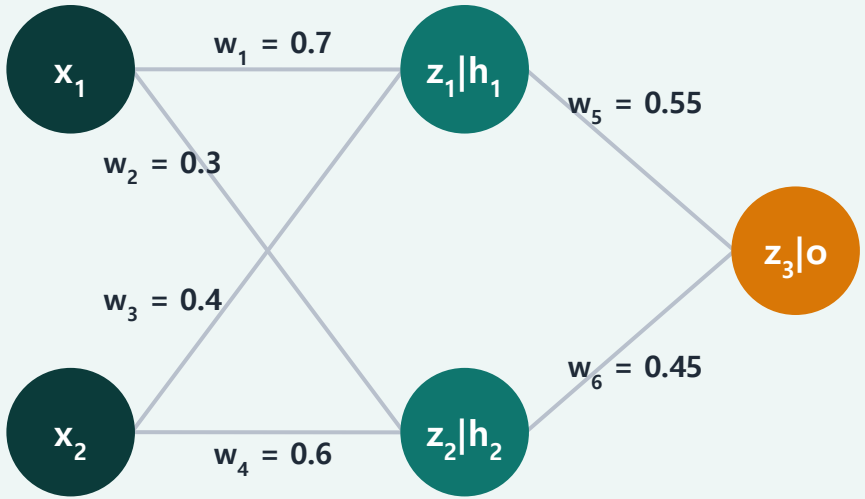
$\delta = \partial L / \partial z$ (그 노드의 오차)

w의 기울기 = (그 w가 들어가는 노드의 δ) × (그 w에 곱해진 입력)

05 역전파 예시

은닉층이 있는 신경망에서 w 6개의 기울기 구하기

예제 신경망



설정

- 입력 $x_1 = 0.8$, $x_2 = 0.6$
- 정답 y = 1 (비)
- 활성화 함수: 모두 시그모이드
- 손실 함수: BCE
- 편향 b는 생략
- 학습률 lr = 0.5

순전파와 loss 계산

노드	선형 변환 z	z	활성화	값
은닉 1	0.8×0.7 + 0.6×0.4	0.800	$h_1 = \sigma(z_1)$	**0.690**
은닉 2	0.8×0.3 + 0.6×0.6	0.600	$h_2 = \sigma(z_2)$	**0.646**
출력	0.690×0.55 + 0.646×0.45	0.670	$o = \sigma(z_3)$	**0.662**

loss $L = -\log(o)$

$-\log(0.662) = 0.413$

비 올 확률 66.2%. 정답 1에 더 가깝게 만들려면 6개의 w를 각각 얼마나 고쳐야 할까?

역전파 ① 출력층 w_5, w_6

$$\delta_3 = \partial L/\partial z_3 = o - y = 0.662 - 1 = -0.338$$

02에서 구한 p – y와 같은 원리예요

w_5 $\partial L/\partial w_5 = \delta_3 \times h_1$

-0.338×0.690 **-0.234**

w에 곱해진 입력 = 은닉층 출력

w_6 $\partial L/\partial w_6 = \delta_3 \times h_2$

-0.338×0.646 **-0.219**

w에 곱해진 입력 = 은닉층 출력

역전파 ② 은닉층 w_1 ~ w_4

$$\delta_1 = \delta_3 \times w_5 \times h_1(1 - h_1) \qquad -0.338 \times 0.55 \times 0.214 = -0.0398$$

$$\delta_2 = \delta_3 \times w_6 \times h_2(1 - h_2) \qquad -0.338 \times 0.45 \times 0.229 = -0.0348$$

뒤에서 받은 오차 δ_3 × 연결 강도 w_5 × 시그모이드 미분 = 은닉 노드의 오차

w	연결	기울기 = δ × 입력	값
w_1	x_1 → 은닉 1	$\delta_1 \times 0.8$	**−0.0319**
w_3	x_2 → 은닉 1	$\delta_1 \times 0.6$	**−0.0239**
w_2	x_1 → 은닉 2	$\delta_2 \times 0.8$	**−0.0279**
w_4	x_2 → 은닉 2	$\delta_2 \times 0.6$	**−0.0209**

업데이트 결과 (lr = 0.5)

w	기존	기울기	새 값
w_1	0.70	−0.0319	**0.716**
w_2	0.30	−0.0279	**0.314**
w_3	0.40	−0.0239	**0.412**
w_4	0.60	−0.0209	**0.610**
w_5	0.55	−0.234	**0.667**
w_6	0.45	−0.219	**0.559**

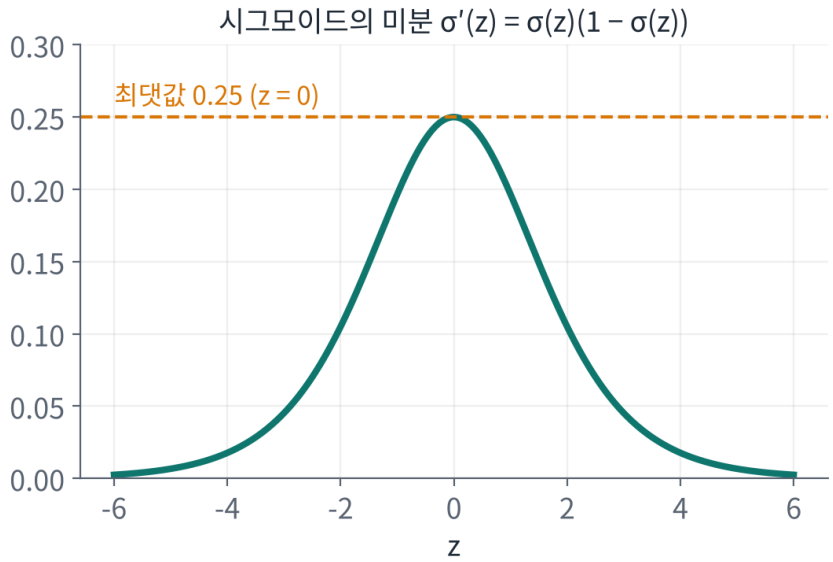
loss

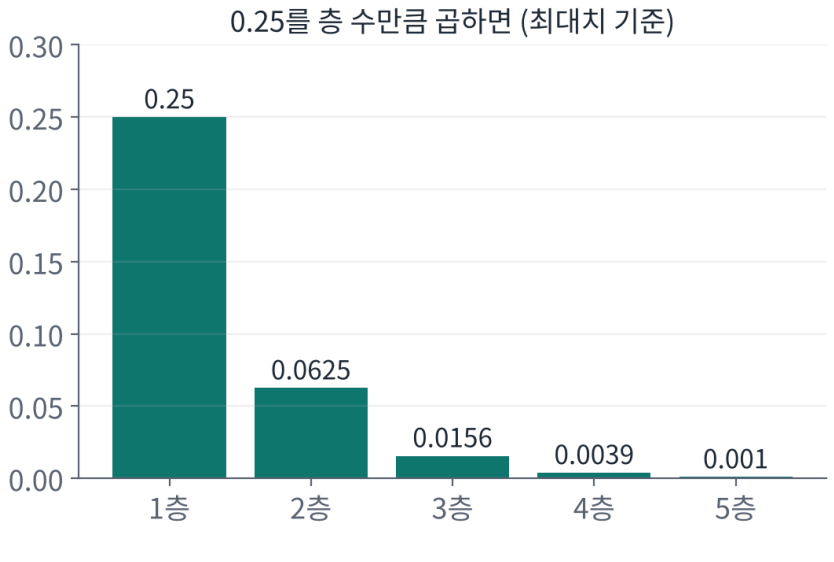
0.413 → 0.363

눈여겨볼 점

은닉층 w의 기울기(약 −0.03)가 출력층 w(약 −0.23)보다 7~8배 작아요. 뒤로 갈수록 시그모이드 미분(최대 0.25)이 곱해지기 때문이에요.

역전파의 한계





local minima: 경사하강법을 쓰므로 가장 낮은 곳이 아닌 웅덩이에 빠질 수 있어요

기울기 소실: 층이 깊으면 작은 미분이 계속 곱해져 앞쪽 w가 거의 학습되지 않아요 → ReLU로 완화

06 실습과 문제

빈칸을 채우고 직접 계산해 보기

실습: 빈칸 채우기

```
for epoch in range(1, 3001):
    for (x1, x2), y in zip(X, Y):
        # 순전파
        h1 = sig(x1*w1 + x2*w3)
        h2 = sig(x1*w2 + x2*w4)
        o  = sig(h1*w5 + h2*w6)
        # 역전파
        d3 = ______                    # ①
        d1 = d3 * ____ * h1*(1-h1)     # ②
        d2 = d3 * w6 * ________        # ③
        # 업데이트
        w5 -= lr*d3*h1;  w6 -= lr*d3*h2
        w1 -= lr*d1*x1;  w3 -= lr*_____   # ④
        w2 -= lr*d2*x1;  w4 -= lr*d2*x2
```

준비

X, Y는 날씨 데이터 7개, w1~w6은 예시 값, lr = 0.5, sig는 시그모이드 함수

힌트

역전파 예시 슬라이드의 δ_3, δ_1, δ_2 식과 w_3의 기울기를 그대로 코드로 옮기면 돼요

확인

3000 epoch 후 7개를 모두 맞히고 평균 loss가 0.01 근처로 내려가면 성공

실습 정답과 실행 결과

빈칸	정답	이유
①	`o - y`	시그모이드 + BCE의 출력층 오차
②	`w5`	은닉 1과 출력을 잇는 연결 강도
③	`h2*(1-h2)`	은닉 2의 시그모이드 미분
④	`d1*x2`	w_3는 x_2 → 은닉 1 연결

epoch	평균 loss	정답
1	0.760	3 / 7
100	0.222	7 / 7
500	0.057	7 / 7
3000	0.010	**7 / 7**

학습이 진행될수록 loss가 계속 줄고, 100 epoch 무렵부터 7개를 모두 맞혀요. 순전파 → 손실 → 역전파 → 업데이트를 데이터마다 반복한 결과예요.

문제 1: 맑은 날 데이터로 dw 구하기

02 날씨 예제와 같은 모델(층 1개, 시그모이드 + BCE)에서
세 번째 데이터 $x_1 = 0.1$, $x_2 = 0.2$, $y = 0$ (맑음), $w_1 = 0.3$, $w_2 = 0.2$, $b = -0.5$일 때

1. z와 p를 구하세요
2. dw_1, dw_2, db를 구하세요
3. w_1은 커질까요, 작아질까요? 그 이유는?

문제 2: 정답이 맑음(y = 0)이라면?

05 역전파 예시의 신경망과 입력(0.8, 0.6)은 그대로 두고
정답만 y = 0으로 바꿨어요. 순전파 결과는 같아요: $h_1 = 0.690$, $h_2 = 0.646$, $o = 0.662$

1. δ_3를 구하세요
2. $\partial L/\partial w_5$를 구하세요
3. δ_1과 $\partial L/\partial w_1$을 구하세요 ($h_1(1 - h_1) = 0.214$)
4. y = 1일 때와 비교해 기울기 부호가 어떻게 달라졌나요?

문제 정답

문제 1

(1) $z = 0.03 + 0.04 - 0.5 = -0.43$

$p = \sigma(-0.43) = 0.394$

(2) $p - y = 0.394$

$dw_1 = 0.394 \times 0.1 = 0.039$

$dw_2 = 0.394 \times 0.2 = 0.079$

$db = 0.394$

(3) 기울기가 양수라 $w_1 -= lr \times dw_1$로 작아져요. 맑은 날인데 39.4%로 예측했으니 p를 낮추는 쪽으로 움직여요.

문제 2

1. $\delta_3 = o - y = 0.662 - 0 = 0.662$
2. $\partial L/\partial w_5 = 0.662 \times 0.690 = 0.456$
3. $\delta_1 = 0.662 \times 0.55 \times 0.214 = 0.0778$

   $\partial L/\partial w_1 = 0.0778 \times 0.8 = 0.0623$
4. y = 1일 때는 기울기가 모두 음수라 w가 커졌는데, y = 0이면 모두 양수가 돼서 w가 작아져요. 출력을 0 쪽으로 낮추는 방향이에요.

정리

01 **체인룰**

이어진 계산은 미분을 곱하고, 경로가 여러 개면 더한다.
$\sigma' = \sigma(1 - \sigma)$

02 **날씨 예제 dw**

$dw = \partial L/\partial p \times \partial p/\partial z \times \partial z/\partial w = (p - y) \times x$

03 **학습 3단계**

순전파 → 손실 계산 → 역전파, 그리고 경사하강법으로 업데이트

04 **역전파**

뒤에서 구한 오차 δ를 앞 층이 재사용.
기울기 = δ × 그 w에 들어온 입력

참고 자료

- 역전파 설명 흐름: yhyun225,「신경망 (3) - 역전파 알고리즘(BackPropagation algorithm)」 yhyun225.tistory.com/22
- 예제 신경망 구조와 w 값, 날씨 데이터: 신박AI「인공신경망과 퍼셉트론」강의

- 문의 : 이해리 iamheddi41@gmail.com